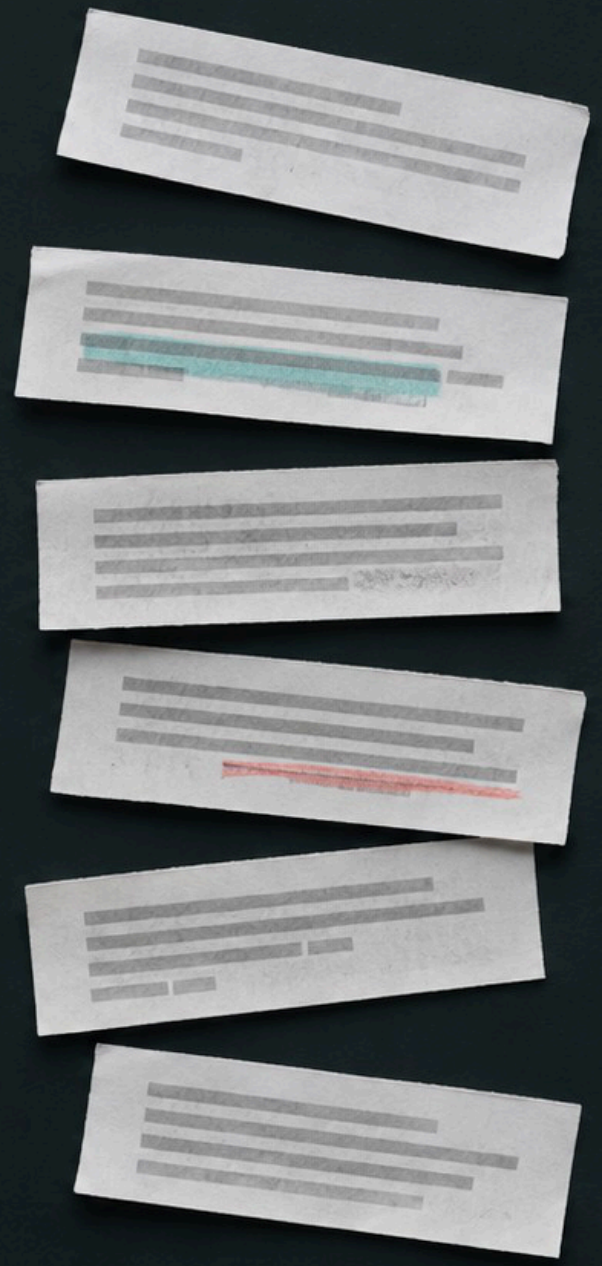
DAMDID 2026

Доразметка и контролируемые пулы кандидатов

Переоценка поисковых моделей на MS MARCO



Наборы данных для оценки поиска

Набор / бенчмарк	Источник и задача
Natural Questions	Запросы Google, ответы в Wikipedia
BEIR	Разные задачи и домены поиска
MS MARCO	**Запросы Bing, поиск по веб-фрагментам**

Почему MS MARCO

Открытые тексты и разреженные оценки релевантности

Источники: Bajaj и др., 2016/2018; Kwiatkowski и др., 2019; Thakur и др., 2021.

Близкие результаты ведущих систем

MS MARCO Passage Ranking, тест eval, исторический срез 30.11.2022

Система	MRR@10
AliceMind SLM + HLAR	0,450
Listwise + Fusion	0,440
CoT-MAE	0,438
Lichee + DeBERTa + reranking	0,436

0,014

размах значений

MRR@10: обратная позиция первого релевантного ответа в топ-10, в среднем.

Близкие метрики не доказывают равенство качества.

Microsoft, четыре ведущие именованные системы в режиме полного поиска.

Релевантный ответ без оценки

«Что вызывает повышение температуры кипения?»

Сокращённый пересказ фрагмента	Исходные оценки	Оценка человека
7112148 Добавление соли повышает температуру кипения.	Релевантен	Релевантен
7399382 Нелетучее растворённое вещество повышает температуру кипения.	Нет оценки	**Релевантен**
987600 Температура кипения ацетона.	Нет оценки	Нерелевантен

qrels: оценки релевантности. Нет оценки: нулевой вклад.
Русский пересказ исходных фрагментов. Метки относятся к оригиналам.

Данные для ручной доразметки

MS MARCO Passage Ranking: 8 841 823 англоязычных фрагмента

dev/small

6 980

запросов в стандартной оценочной подвыборке

7 437 исходных положительных пар

Ручная подвыборка из dev/small

1 179

запросов с дополнительными человеческими оценками

33 667 пар «запрос – фрагмент»

Доразметка охватывает отобранных кандидатов для каждого запроса.

Разметка с известным релевантным ответом



Известный ответ используется при отборе кандидатов и ручной разметке.

Больше оценок в тех же пулах

Среднее число релевантных фрагментов на запрос

1,05

17,47

Исходные оценки

1 243 релевантные пары

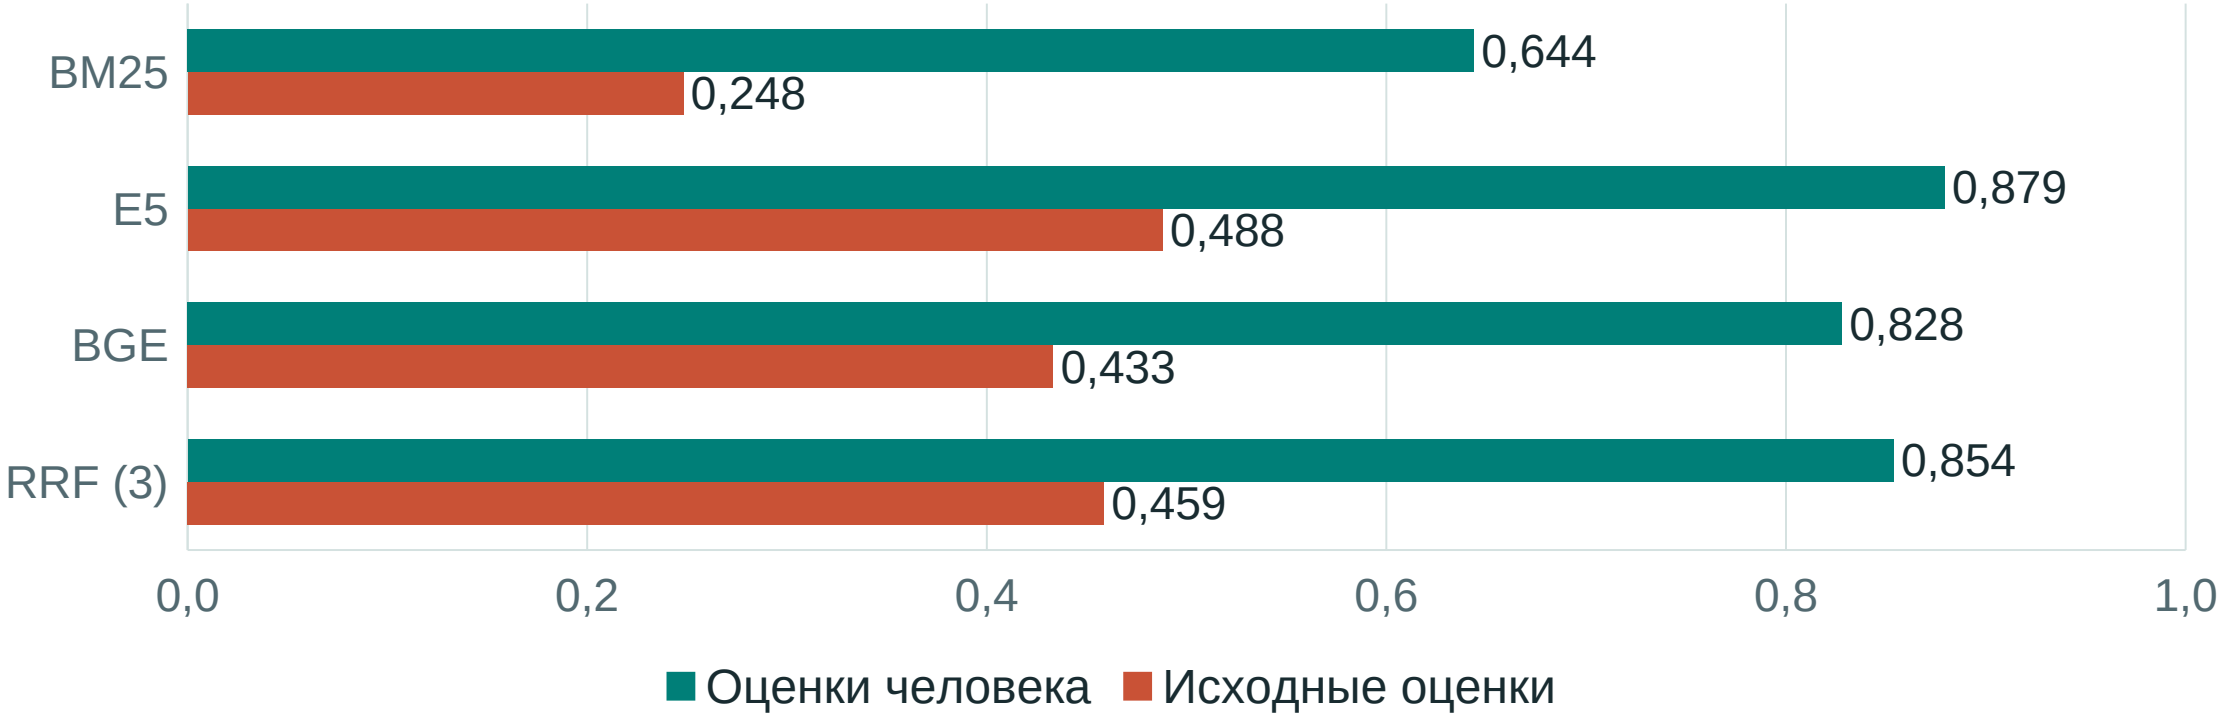
После доразметки

20 597 релевантных пар

1 179 запросов. Пулы кандидатов и порядок поисковой выдачи неизменны.

Доразметка меняет оценку NDCG@10

RRF: объединение выдач BM25, E5 и BGE по обратным рангам

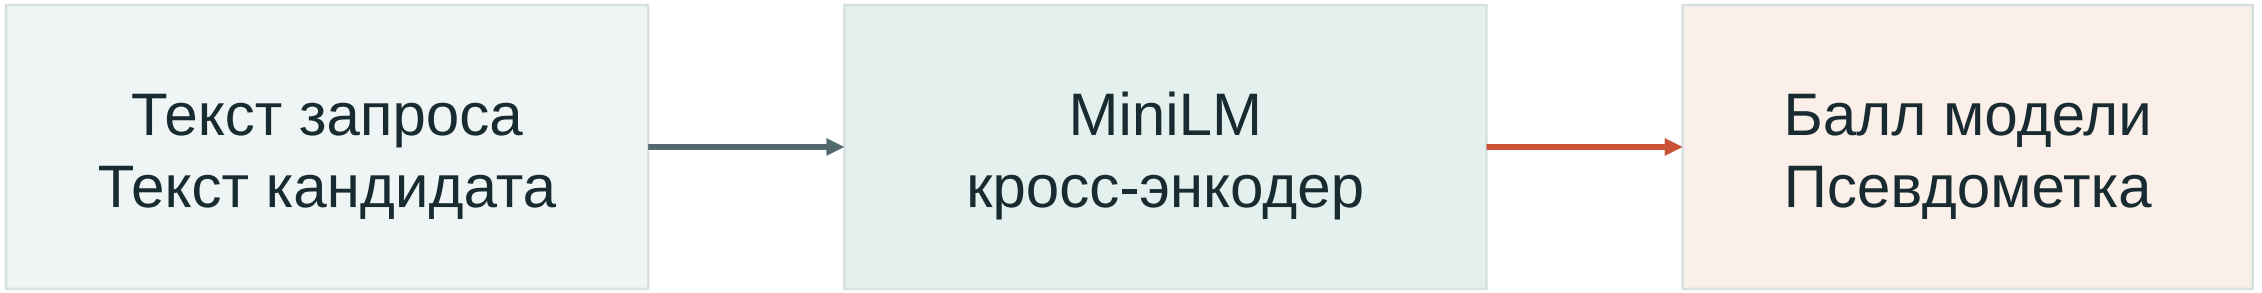


Изменение E5: +0,391 ДИ 95% [0,365; 0,417]

NDCG@10 внутри пулов. Общий идеальный знаменатель для запроса и набора меток.

Модель-судья для больших пулов

Ручные оценки обучают судью для автоматической разметки.

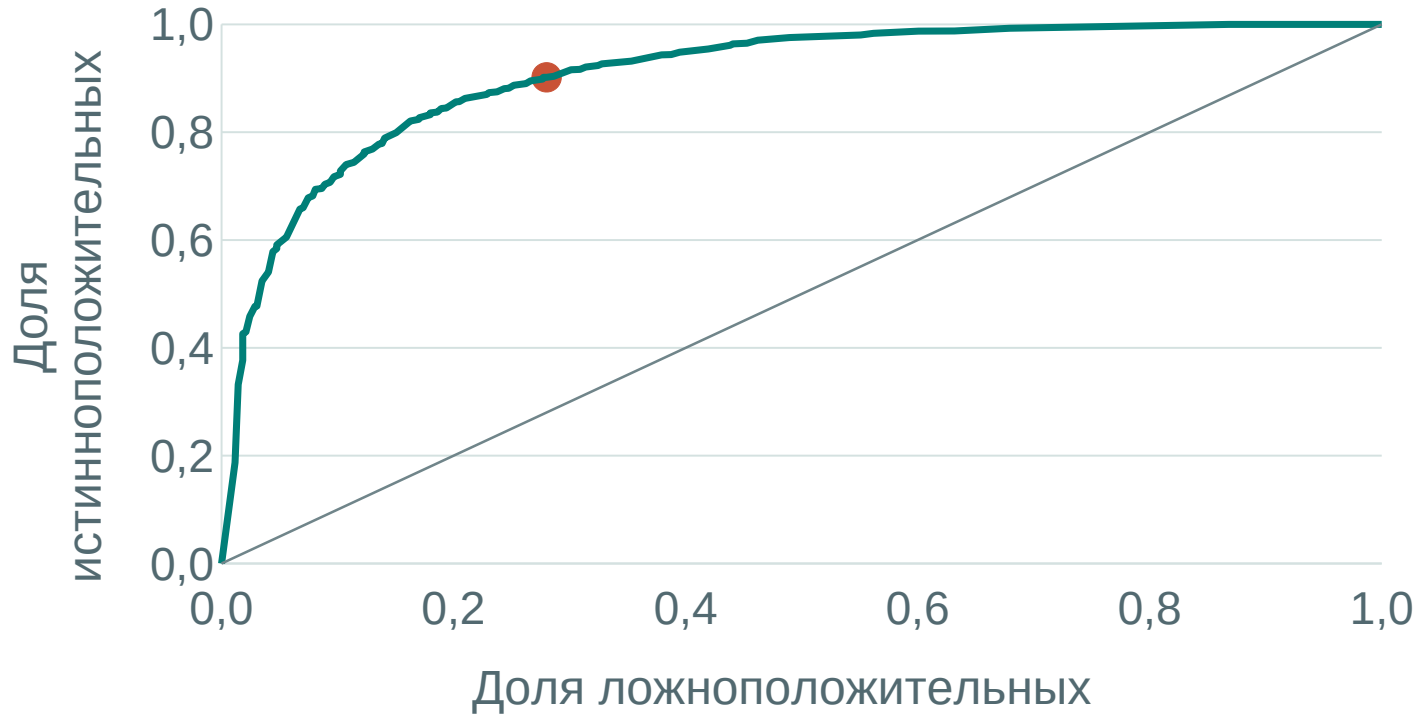


Совместно оценивает два текста

На входе нет эталонного ответа, рангов и баллов поисковых моделей.

Согласие судьи с ручной разметкой

Тест: 177 отложенных запросов, 5 002 пары из ручных пулов



0,907

ROC-AUC

0,875

F1 при выбранном пороге

Порог −0,2187 выбран на валидационных запросах

Для глубоких пулов нет независимой ручной проверки.

Полная dev-часть для масштабной оценки

101 093

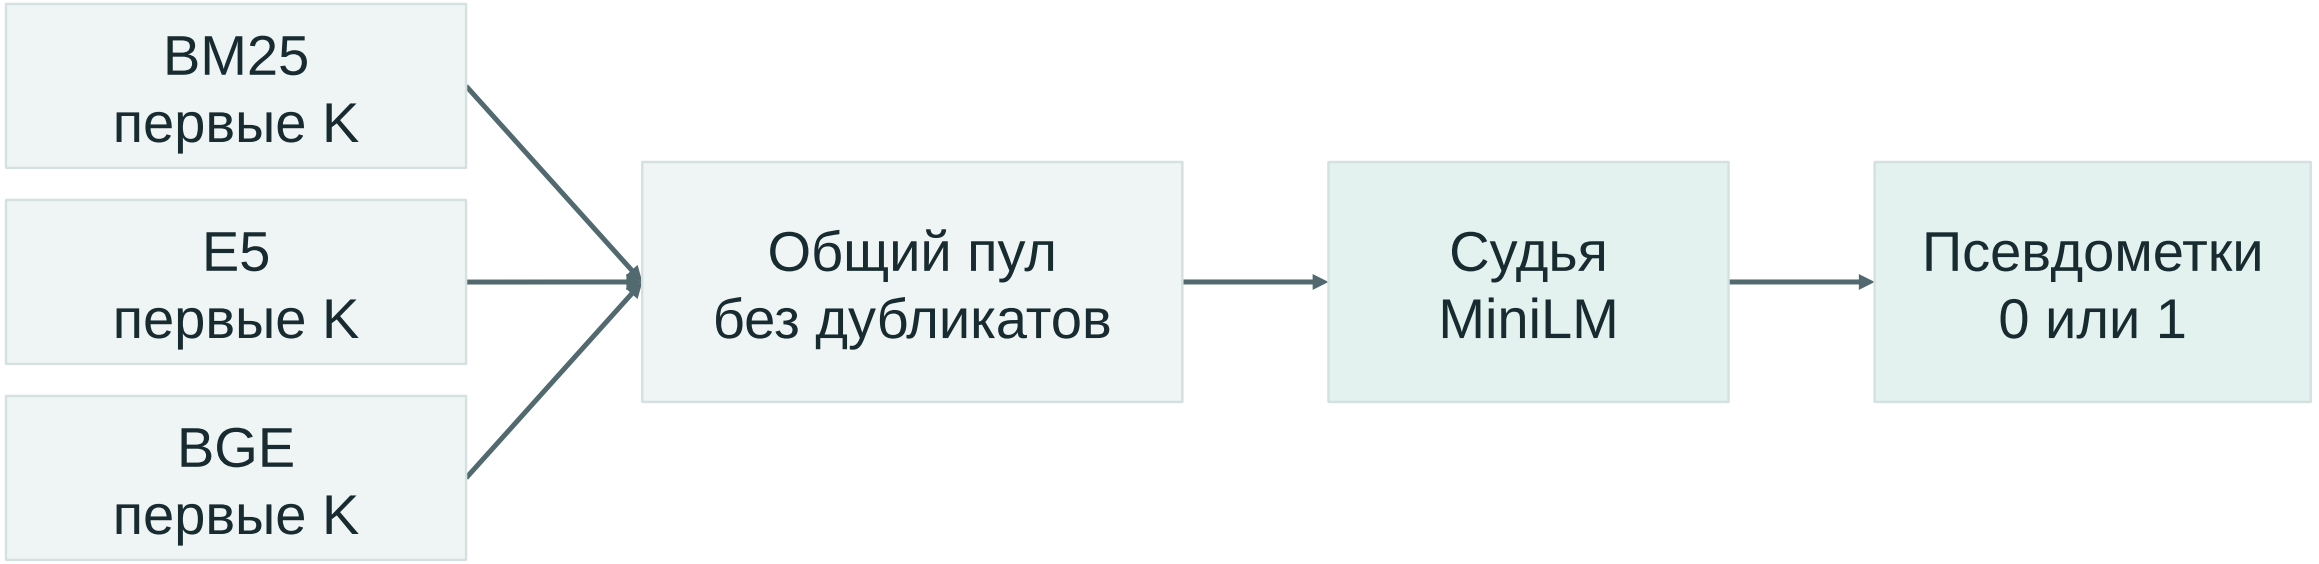
запроса в полной dev-части

MS MARCO Passage Ranking v1

Для этих запросов подготовили поисковые выдачи.
После обучения судья оценивает найденные фрагменты.

Пулы кандидатов для модели-судьи

K задаёт число результатов от каждого поискового метода



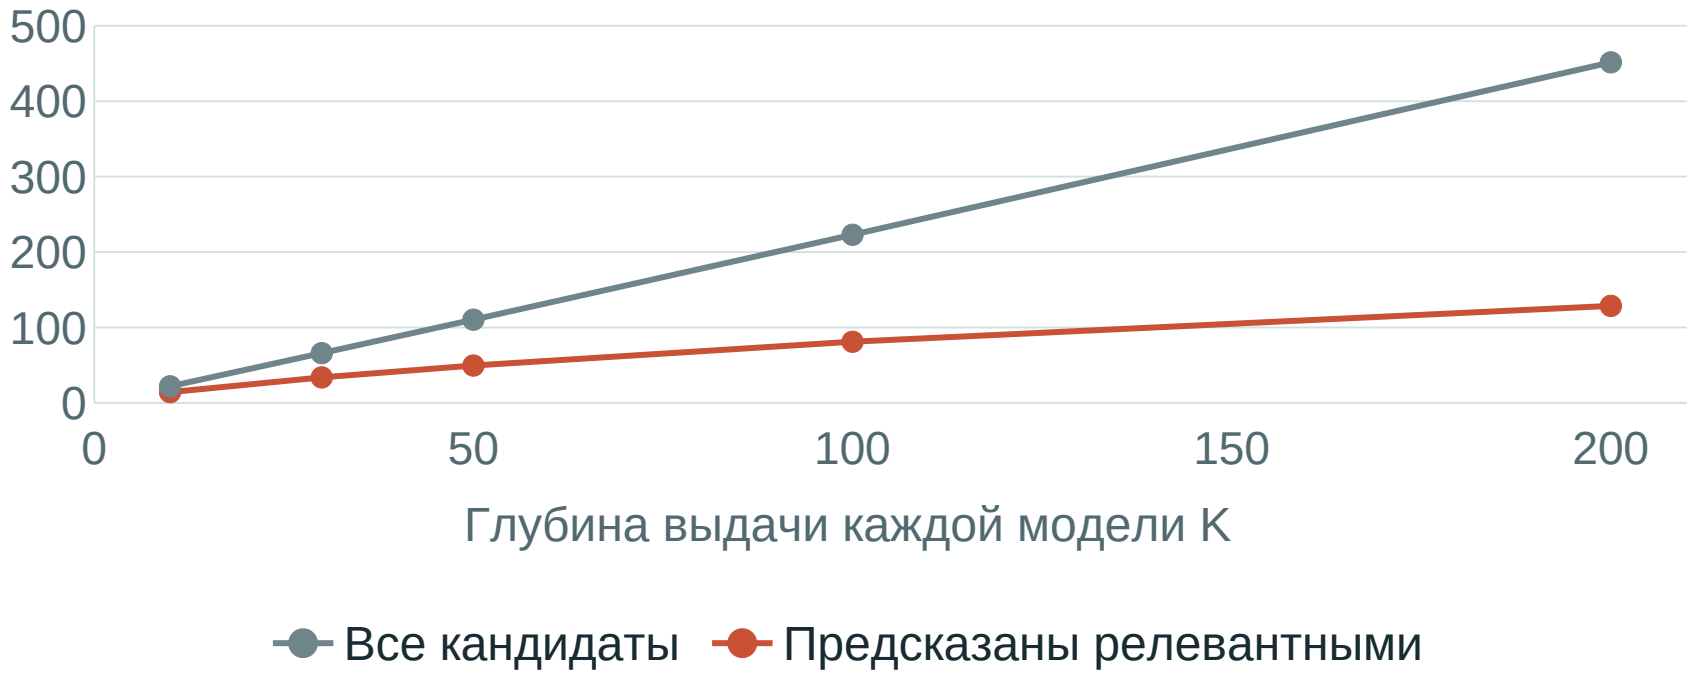
K = 10, 30, 50, 100, 200

Судья и порог −0,2187 фиксированы. Размер пула может быть меньше 3K.

Размер пула и предсказанная релевантность

K: число результатов каждой модели для оценочного пула

Среднее число фрагментов на запрос



451,5

кандидата

128,6

по судье
при K = 200

101 093 запроса, включая пулы без положительных меток. Судья и порог неизменны.

Зачем объединять результаты с помощью RRF

Проверяем, дополняют ли друг друга разные способы поиска



$RRF(d) = \Sigma\ 1 / (60 + rank_i(d))$

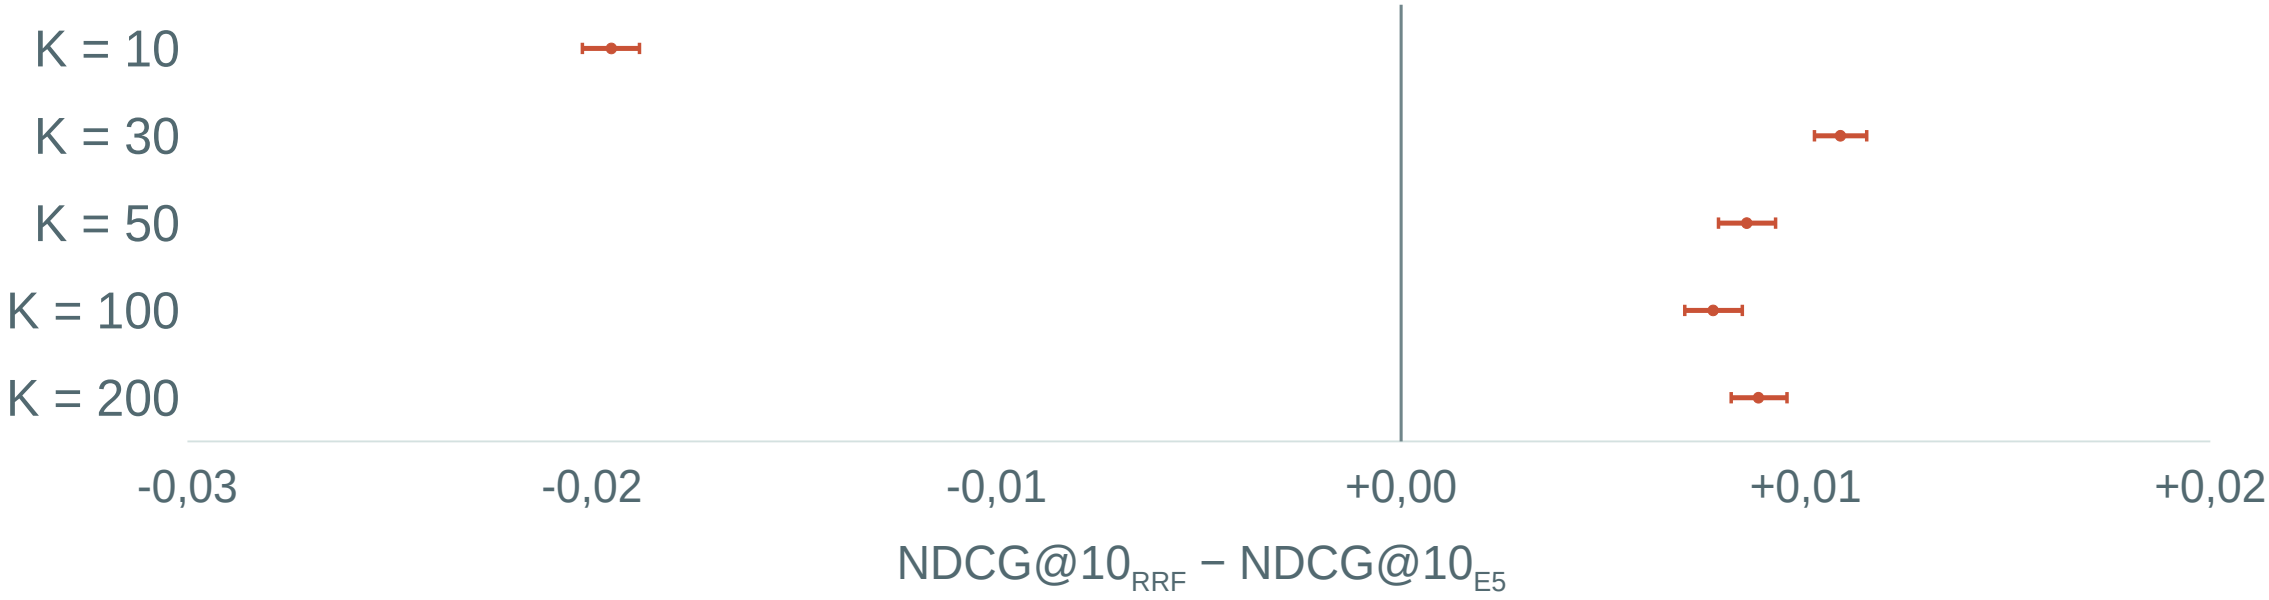
Равный вес источников. Учитываем списки, в которых найден фрагмент.

Cormack, Clarke, Büttcher, SIGIR 2009. Оценки судьи не входят в формулу RRF.

Меняются пул и входные списки RRF

K: глубина пула L: глубина входных списков RRF

L = K. Более глубокие списки могут менять итоговый топ-10.



При K = 200 разность NDCG@10 составляет +0,0088

Один судья. Парный ДИ 95% [0,0082; 0,0095].

Покрытие разметкой меняет сравнение

$NDCG@10_{RRF} - NDCG@10_{E5}$

Меняется только K. L = 200, обе выдачи зафиксированы.



14,4%

пар из топ-10 RRF вне оценочного пула при K = 10

145 643 пары «запрос–фрагмент»

K = 10: −0,0661

K = 30: +0,0080

Отсутствие оценки дает нулевой вклад в метрику, но не означает нерелевантность.

Устойчивость и ограничения

В обоих расчетах используются только псевдометки судьи

Запросы	Число	Сравнение RRF и E5
Полная dev-часть	101 093	Базовое сравнение
Без 1 179 запросов ручной подвыборки	99 914	На тех же K лидирует та же система

Ручные пулы: известный ответ, согласие экспертов не измерено.

Большие пулы: один судья, без независимой ручной проверки.

Перенос за пределы выбранных пулов английского MS MARCO не проверен.

Полнота разметки влияет на сравнение систем

Ручная доразметка меняет оценку качества

E5 NDCG@10: с 0,488 до 0,879

Та же выдача, более полная разметка

При фиксированной выдаче и одном судье

Вывод о лучшей системе зависит от охвата разметки

Направления дальнейшего исследования
Улучшить судью и проверить доразметку по оценкам человека

Результаты для выбранных пулов английского MS MARCO.

Литература и ресурсы

MS MARCO
Bajaj et al., 2016
arxiv.org/abs/1611.09268

Natural Questions
Kwiatkowski et al., 2019
aclanthology.org/Q19-1026

BEIR
Thakur et al., 2021
arxiv.org/abs/2104.08663

BM25
Robertson & Zaragoza, 2009
doi.org/10.1561/1500000019

E5
Wang et al., 2022
arxiv.org/abs/2212.03533

BGE / FlagEmbedding
Модель bge-small-en-v1.5
huggingface.co/BAAI/bge-small-en-v1.5

MiniLM
Wang et al., 2020
arxiv.org/abs/2002.10957

Reciprocal Rank Fusion
Cormack et al., 2009
doi.org/10.1145/1571941.1572114

Спецификация dev и dev/small: ir-datasets.com/msmarco-passage.html

Спасибо за внимание

Вопросы и обсуждение

Какие части данных мы использовали

Набор	Запросы	Роль в исследовании
Полная dev-часть	101 093	Масштабная оценка судьёй
dev/small	6 980	Исходная оценочная подвыборка
Ручная подвыборка	1 179	Доразметка 33 667 пар
Обучение судьи	825	Дообучение на ручных метках
Валидация судьи	177	Выбор порога
Тест судьи	177	Проверка на отложенных запросах

Ручная подвыборка входит в dev/small, а dev/small входит в полную dev-часть.

NDCG@10 и эффект доразметки

NDCG@10 = DCG@10 / идеальный DCG@10

Система	После − до	Парный ДИ 95%
BM25	+0,396	0,372 ... 0,419
E5	+0,391	0,365 ... 0,417
BGE	+0,395	0,369 ... 0,419
RRF (3)	+0,395	0,371 ... 0,419

5 000 парных бутстрэп-выборок по запросам. Для всех четырёх эффектов $p < 0{,}001$.

Проверка судьи и ошибки

Обучение	Валидация	Тест
825	**177**	**177**

Метка в тесте	Прогноз: нет	Прогноз: да
Отрицательная	1 300	506
Положительная	314	2 882

Точность 0,851 **Полнота 0,902** **F1 0,875**

5 002 пары: 6 неясных меток кодируются нулём, у 1 записи пустой текст.

Результаты при разной глубине пула

K	Кандидатов на запрос	Релевантных по судье на запрос	E5 NDCG@10	RRF L=K NDCG@10	RRF L=200 NDCG@10
10	21,9	14,2	0,871	0,852	0,805
30	65,8	33,7	0,851	0,862	0,859
50	110,4	49,4	0,847	0,856	0,856
100	222,9	81,0	0,844	0,851	0,853
200	451,5	128,6	0,842	0,850	0,850

Псевдометки одного судьи. В каждом среднем учтены все 101 093 запроса.

Проверка качества ручных данных

Ручная разметка: проверка без 23 запросов

Система	Все 1 179 запросов	1 156 после исключения
BM25	0,644	0,644
E5	0,879	0,879
BGE	0,828	0,828
RRF (3)	0,854	0,855

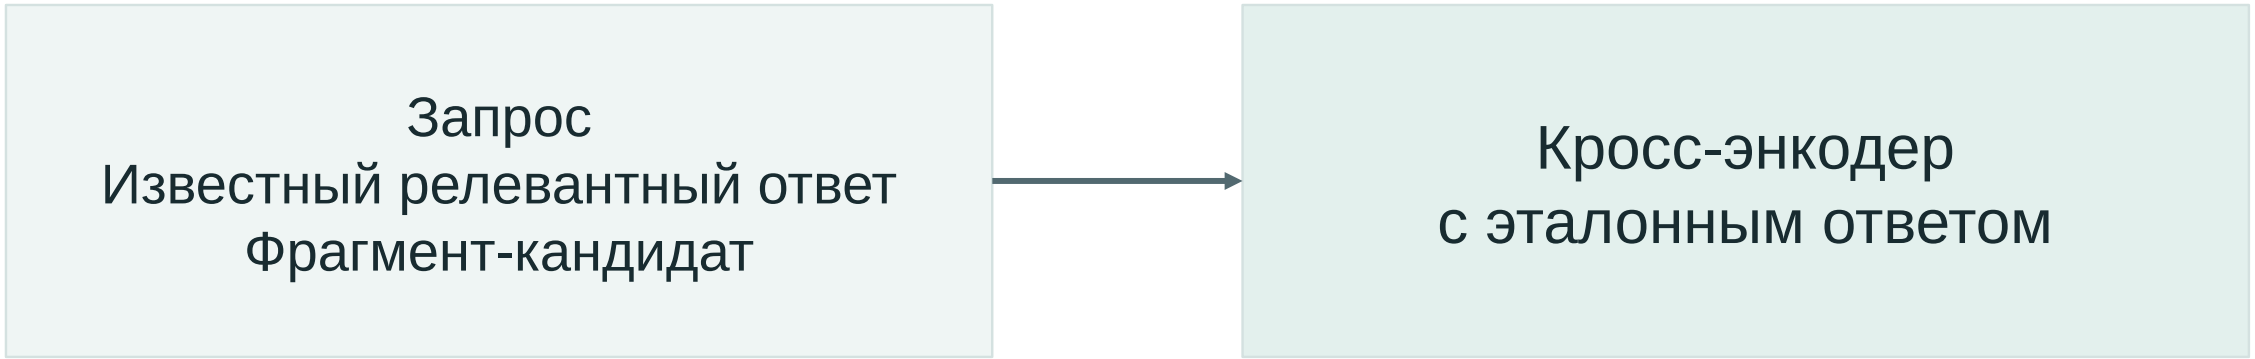
29 пар с метками 3, 20 или 22; 5 пар без текста

Затронуты 23 запроса. После исключения осталось 1 156.

Коды вне шкалы 0/1/2 не считали подтвержденными оценками.

Судья с эталонным ответом

Предлагаемый вход



Сравнение более сильных судей по независимым человеческим оценкам

Запланированный эксперимент. Результаты для такого судьи пока не получены.