Текст выступления DAMDID 2026

Доразметка и контролируемые пулы кандидатов для переоценки поисковых моделей на MS MARCO

Русскоязычный доклад по слайдам 1–16. Слайды 17–22 оставлены для вопросов. Расчётный хронометраж: 14:55 при темпе около 120 слов в минуту с короткими переходами. Точное время проверьте на репетиции. Заголовки и отметки времени не нужно зачитывать.

Слайд 1 Оценка поиска на MS MARCO

0:00–0:45

поисковых систем зависит от того, какие найденные тексты получили оценку релевантности?

В докладе используется уточнённый численный протокол: общий идеальный знаменатель метрики и единый набор запросов для сравниваемых систем. Поэтому некоторые значения и вывод о слиянии выдач отличаются от редакторской версии рукописи. Сегодня я последовательно покажу, что именно измеряется: сначала на человеческой разметке, затем на предсказаниях модели.

Слайд 2 Почему MS MARCO

0:45–1:35

Для оценки поиска существуют разные наборы данных. Natural Questions связывает реальные запросы Google с ответами в Википедии. BEIR объединяет задачи из разных предметных областей и помогает исследовать переносимость поисковых методов. Эти коллекции отвечают на разные исследовательские вопросы.

Мы выбрали MS MARCO, основанный на запросах Bing и открытых текстах веб-фрагментов. Для нас особенно важна разреженность исходных оценок: подходящий ответ может присутствовать в корпусе, но отсутствовать в разметке. Здесь можно изучить, как дополнительные оценки меняют сравнение уже полученных выдач. При этом выбор удобного исследовательского набора ещё не делает его представителем всех языков, предметных областей и поисковых сценариев.

Слайд 3 Близкие метрики в официальном лидерборде

1:35–2:30

Для контекста покажу финальный срез официального лидерборда на 30 ноября 2022 года. Эта задача закрыта с 1 января 2023 года, поэтому перед нами исторический ориентир, а не лучшие системы 2026 года. Четыре приведённые системы сравниваются в одной постановке полного поиска на закрытом тестовом наборе.

Их значения MRR@10 лежат между 0,436 и 0,450. Метрика усредняет обратную позицию первого релевантного ответа в первой десятке. Близость чисел сама по себе не доказывает ни эквивалентность систем, ни неполноту разметки. Она лишь мотивирует внимательнее посмотреть на основания сравнения. Дальше мы используем другие запросы и другую метрику, NDCG внутри размеченных пулов; напрямую сопоставлять эти числа нельзя.

Слайд 4 Правильный ответ может остаться без оценки

2:30–3:20

Рассмотрим запрос: что вызывает повышение температуры кипения? Первый фрагмент говорит о добавлении соли и отмечен как релевантный в исходной разметке. Второй объясняет действие нелетучего растворённого вещества. Человек тоже признаёт его релевантным, но исходной оценки для него нет. Третий сообщает температуру кипения ацетона и не отвечает на вопрос о причине повышения.

На слайде дан русский пересказ; оценки относятся к исходным английским текстам. Такие оценки обычно называют qrels. В нашем расчёте документ без оценки получает нулевой вклад. Поэтому полезный найденный ответ может не принести системе баллов. Важно различать отсутствие оценки и установленную нерелевантность: это разные состояния данных.

Слайд 5 Две части эксперимента

3:20–4:10

В англоязычной коллекции MS MARCO около 8,84 миллиона фрагментов. Наше исследование состоит из двух частей. В ручной части рассматриваются 1179 запросов и примерно 34 тысячи пар «запрос и фрагмент». В масштабной части мы используем сохранённые предсказания модели-судьи для кандидатов по более чем ста тысячам запросов.

Эти части дают разные основания для выводов. Первая показывает эффект человеческой доразметки при неизменных выдачах. Вторая позволяет менять глубину пула, но опирается на машинные метки. Под углублённой доразметкой мы понимаем оценивание многих кандидатов внутри заданного пула. Мы не утверждаем, что нашли и оценили все релевантные тексты во всём корпусе.

Слайд 6 Как сформирован ручной пул

4:10–5:05

Ручной пул получен объединением нескольких списков с удалением дубликатов. BM25 ищет по лексическим совпадениям. E5 и BGE кодируют запрос и фрагмент отдельно и сравнивают их векторные представления. От каждого из этих методов в ручной пул входят десять результатов.

Есть и дополнительные каналы отбора, включая E5-rerank и сходство с заранее известным релевантным ответом. Их не следует смешивать. Разметчик также видит этот ответ вместе с запросом и кандидатом. Таким образом, эталон влияет и на отбор текстов, и на условия человеческой оценки. В среднем получается около 29 кандидатов на запрос. Это целенаправленно обогащённая выборка, поэтому долю релевантных фрагментов в ней нельзя переносить на весь корпус.

Слайд 7 Что измеряет NDCG@10

5:05–6:15

Прежде чем смотреть результаты, поясню метрику. NDCG@10 оценивает первые десять позиций выдачи. У нас релевантность бинарная: обе положительные категории ручной разметки дают единицу. Чем выше стоит релевантный фрагмент, тем больше его вклад. Для первых трёх позиций веса примерно равны 1, 0,63 и 0,50. Это иллюстрация формулы, не отдельный эксперимент.

Сумму таких вкладов делим на идеальную сумму для этого запроса, используя положительные метки всего оценочного пула. При фиксированном наборе меток идеальный знаменатель одинаков у всех систем. Но при расширении разметки он может измениться.

Документ без оценки даёт нулевой вклад и остаётся на своей позиции: последующие результаты не сдвигаются вверх. Если положительных меток нет и идеальный знаменатель равен нулю, принимаем NDCG равной нулю. Такой запрос остаётся в общем среднем. Поэтому при сравнении глубин мы не подменяем набор запросов более удобной подвыборкой.

Слайд 8 Доразметка раскрывает пропущенные ответы

6:15–7:05

Теперь вернёмся к ручной выборке. В тех же пулах исходные оценки дают в среднем чуть больше одного релевантного фрагмента на запрос, а после человеческой доразметки получается около семнадцати с половиной. Это показывает, сколько положительных ответов обнаруживается среди уже отобранных кандидатов.

Рост не означает, что исходные положительные оценки были ошибочны. Многие другие фрагменты просто не имели оценки. Вместе с тем человеческая разметка здесь выполнена с опорой на известный ответ и принятый критерий релевантности. Независимое согласие разметчиков не измерялось. Для следующего сравнения сохраняем запросы, состав пулов и порядок результатов. Меняем только метки, по которым рассчитываем NDCG.

Слайд 9 Выдача та же. Измеренная оценка выше

7:05–8:05

На графике показаны BM25, E5, BGE и RRF. Последний объединяет три поисковые выдачи по обратным рангам: использует позиции документов, а не исходные баллы моделей. При замене исходных оценок человеческими среднее значение NDCG растёт у всех четырёх систем.

Для E5 оно меняется с 0,488 до 0,879. Средняя парная разность составляет 0,391, а её 95-процентный доверительный интервал лежит от 0,365 до 0,417. Интервал получен повторной выборкой запросов. Остальные значения не буду перечислять: важен общий характер изменения.

Поисковые модели при этом не переобучались, и выдача не стала лучше. Изменилась её измеренная оценка. Порядок систем также сохранился: E5, затем RRF, BGE и BM25. Это результат для наших размеченных пулов, а не новое достижение в официальном лидерборде.

Слайд 10 Зачем нужна модель-судья

8:05–8:55

Оценивать вручную более глубокие пулы для большого числа запросов дорого. Поэтому мы дообучаем компактный кросс-энкодер MiniLM на человеческих метках и используем его как модель-судью. Она совместно обрабатывает текст запроса и текст кандидата, затем выдаёт балл, который сравнивается с выбранным порогом.

Судья не получает известного релевантного ответа, рангов или баллов BM25, E5 и BGE. Он также не заменяет первый этап поиска: кандидатов по-прежнему находят поисковые системы. Его задача здесь только присвоить им псевдометки. Порог выбирается на валидационных запросах и далее фиксируется. Такое разделение ролей важно: качество генерации кандидатов и согласие судьи с человеком проверяются по-разному.

Слайд 11 Проверка судьи на отложенных запросах

8:55–9:55

Ручные данные разделены по запросам: все кандидаты одного запроса находятся в одной части. На тест приходятся 177 запросов, которые не использовались для нашего дообучения и выбора порога. На них ROC-AUC составляет 0,907, а F1 при выбранном пороге примерно 0,875.

Эти показатели характеризуют согласие с человеческими метками внутри ручных пулов. Они не гарантируют такую же точность на глубоких пулах или отсутствие предпочтения к выдачам определённых систем.

Есть и граница понятия «отложенные»: базовая модель уже обучалась на MS MARCO. Наше разбиение контролирует локальное дообучение, но не доказывает отсутствие пересечений на всех предшествующих этапах. Поэтому далее говорим об оценивании по одному конкретному судье, а не о независимой человеческой проверке.

Слайд 12 Глубина пула меняет число псевдометок

9:55–10:50

В масштабной части объединяем первые K результатов BM25, E5 и BGE. K обозначает глубину каждого исходного списка, а не число уникальных кандидатов после удаления повторов. Предсказания судьи и порог решения при изменении глубины остаются теми же.

Когда K увеличивается от десяти до двухсот, средний пул растёт примерно от 22 до 452 кандидатов. Положительных псевдометок становится больше: примерно от 14 до 129 на запрос. Во всех средних учитываются и запросы без положительных меток.

Такой рост нельзя читать как оценку полного числа правильных ответов в коллекции. Мы предъявляем судье больше отобранных текстов и получаем больше положительных решений. Это характеристика данного протокола.

Слайд 13 Совместное изменение глубин пула и RRF

10:50–11:45

Для сравнения RRF с E5 нужно различить два параметра. K задаёт глубину оценочного пула. L задаёт глубину списков, которые поступают на слияние RRF. В этом опыте они меняются вместе: L равно K. Следовательно, меняются и доступные метки, и сама объединённая выдача.

При минимальной глубине RRF уступает E5, а на больших глубинах разность становится положительной. При K, равном двумстам, она составляет около 0,0088. Это небольшой эффект, хотя парный доверительный интервал не включает ноль.

Интервал условен относительно фиксированного судьи и не учитывает ошибки его разметки или неопределённость обучения. По этому опыту нельзя отдельно приписать эффект изменению охвата разметки или входных списков RRF. Для этого нужен следующий контроль.

Слайд 14 Ключевой опыт: выдача зафиксирована

11:45–12:55

Теперь RRF всегда объединяет первые двести результатов каждого источника. Его топ-10 и топ-10 E5 фиксированы. Меняем только глубину оценочного пула. При K, равном десяти, разность RRF минус E5 составляет минус 0,0661, а при K, равном тридцати, уже плюс 0,0080.

Откуда изменение? Топ-10 E5 целиком входит в пул уже при K, равном десяти. У фиксированного RRF за его пределами остаются 14,4 процента пар из первой десятки. Пока оценки нет, их вклад нулевой. Расширение пула открывает эти оценки, а также может увеличить общий идеальный знаменатель. Поэтому NDCG E5 может снижаться при неизменных выдаче и DCG.

Получается, измеряемый порядок систем меняется без изменения поиска. Но небольшое среднее преимущество RRF не означает выигрыша на большинстве запросов: при максимальной глубине больше половины сравнений дают равенство. Тем более это не доказательство заметного улучшения пользовательского опыта.

Слайд 15 Что проверено, а что ещё нет

12:55–13:55

Мы проверили чувствительность к двум исключениям. Удаление 23 ручных запросов с неясными категориями или пустыми текстами не меняет порядок систем. Большой набор включает все 1179 ручных запросов, в том числе использованные при дообучении судьи. После исключения всей этой группы остаётся 99 914 запросов, и знаки различий RRF и E5 сохраняются на проверенных глубинах.

Эта проверка снижает опасение, что результат объясняется только пересечением запросов. Однако независимых человеческих оценок глубоких пулов она не добавляет. Судья остаётся один, а ручная разметка использует эталонный ответ. При пересчёте проверены сохранённые баллы; повторное обучение судьи не выполнялось.

Выводы относятся к выбранным английским пулам, конкретным версиям E5, BGE и MiniLM. Перенос численных эффектов на другие языки, домены и модели пока не проверен.

Слайд 16 Главные выводы

13:55–14:55

Итак, два результата. Первый: дополнительная человеческая разметка существенно меняет измеренную оценку уже полученной выдачи, хотя сама поисковая система не меняется. Второй: в опыте с фиксированными выдачами расширение пула меняет даже порядок RRF и E5 по псевдометкам одного судьи.

Поэтому вместе с метрикой нужно сообщать состав пула, источник меток и настройки слияния. Следующий шаг мы рассматриваем как офлайн-разметку: сравнить более сильных судей с доступом к известному релевантному ответу и без него, проверяя решения по независимым человеческим оценкам. Это план исследования, а не уже полученный результат и не предложение давать эталон обычной поисковой системе.