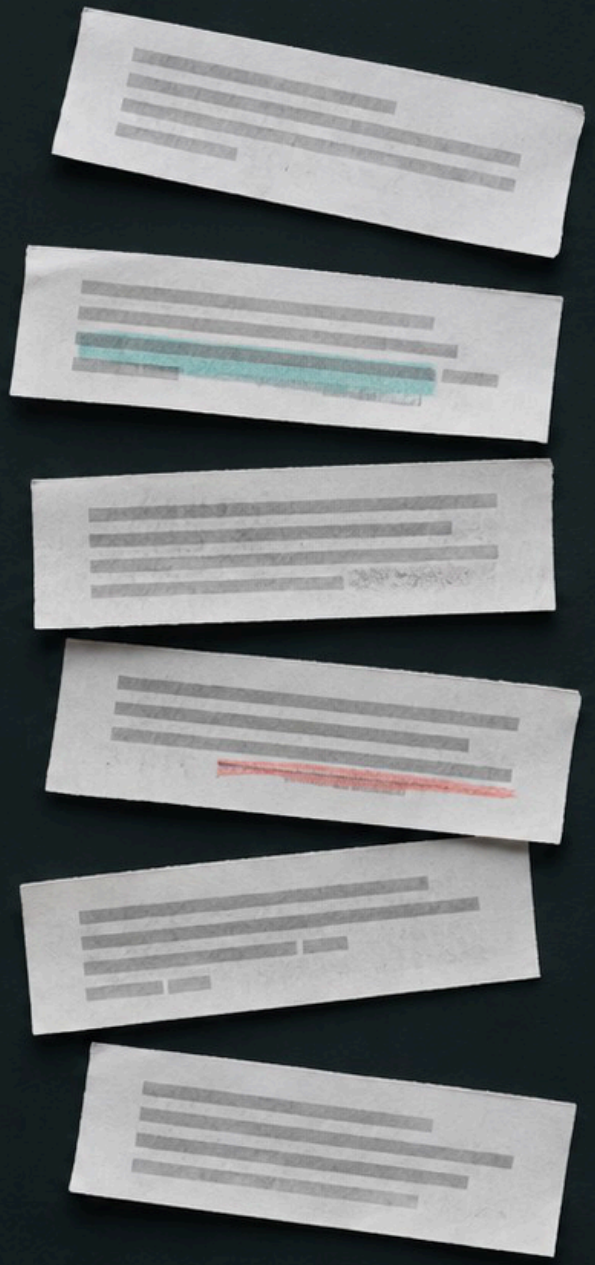
DAMDID 2026

Оценка поиска на MS MARCO

Доразметка и контролируемые пулы кандидатов

Как меняется оценка неизменной выдачи



Почему MS MARCO

Разные коллекции отвечают на разные вопросы о качестве поиска

Набор / бенчмарк	Что позволяет проверить
Natural Questions	Ответы на реальные запросы Google
BEIR	Перенос между задачами и доменами
MS MARCO	**Ранжирование веб-фрагментов для запросов Bing**

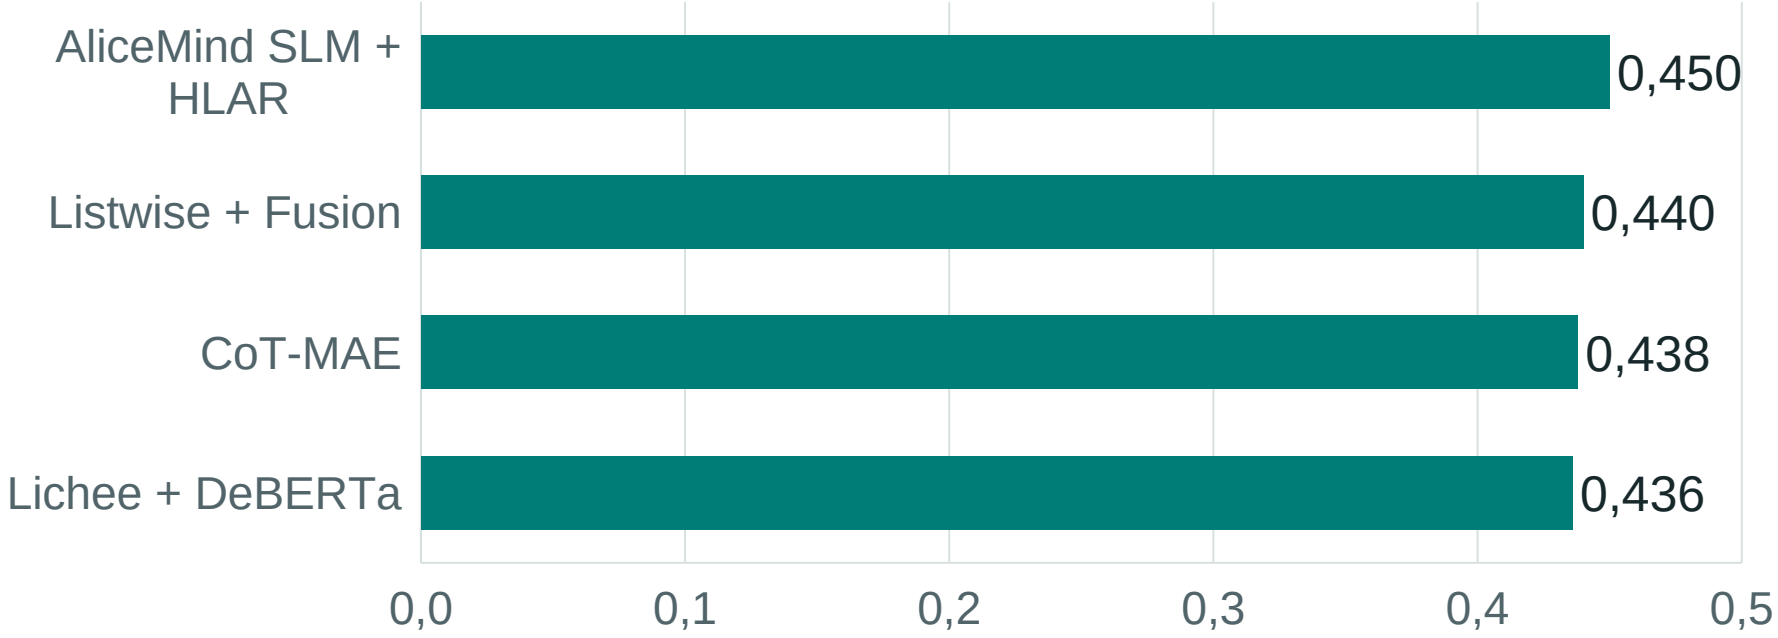
Открытые тексты + неполные оценки релевантности

Подходящая постановка для изучения эффекта доразметки

Источники: Bajaj и др., 2016/2018; Kwiatkowski и др., 2019; Thakur и др., 2021.

Близкие метрики в официальном лидерборде

MS MARCO Passage Ranking · полный поиск · закрытый eval



0,014

размах MRR@10

Близкие средние не доказывают эквивалентность систем

MRR@10 учитывает позицию первого найденного релевантного ответа.

Последний официальный срез: 30.11.2022. Трек закрыт 01.01.2023. Четыре именованные заявки.

Правильный ответ может остаться без оценки

«Что вызывает повышение температуры кипения?»

Сокращённый пересказ фрагмента	Исходные оценки	Оценка человека
7112148 Добавление соли повышает температуру кипения.	Релевантен	Релевантен
7399382 Нелетучее растворённое вещество повышает температуру кипения.	Нет оценки	**Релевантен**
987600 Температура кипения ацетона.	Нет оценки	Нерелевантен

Нет оценки ≠ нерелевантен

В метрике: нет оценки → нулевой вклад. Русский пересказ; метки относятся к оригиналам.

Две части эксперимента

Английский MS MARCO: 8,84 млн текстовых фрагментов

Ручные оценки

1 179

запросов · 33 667 пар

Что меняет доразметка при той же выдаче?

Псевдометки судьи

101 093

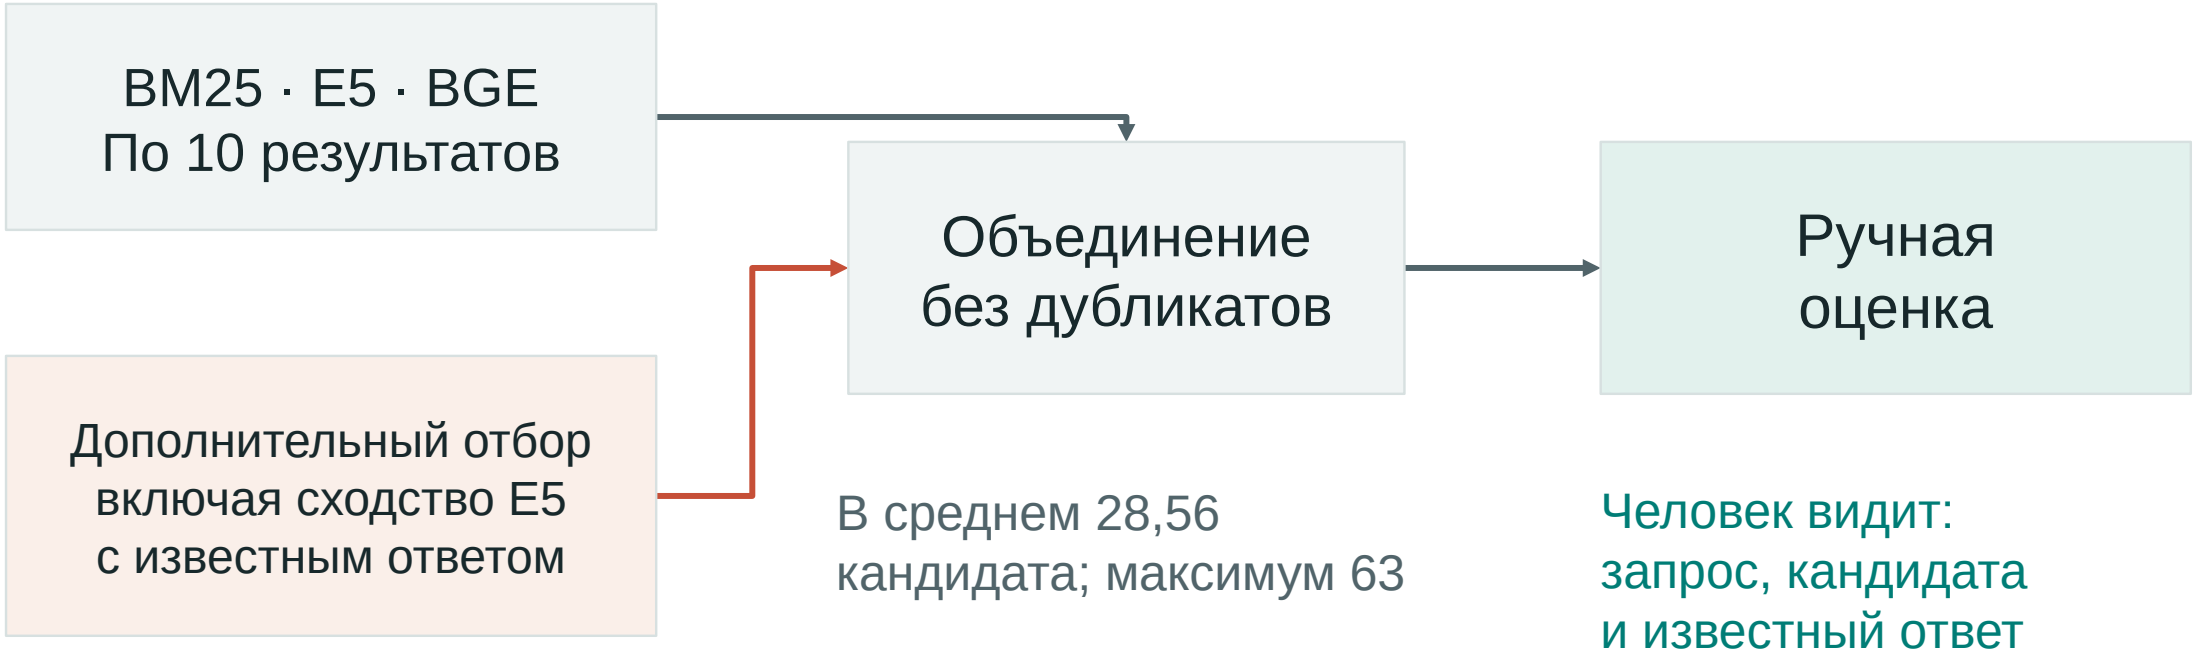
запроса · пять глубин пула

Как покрытие оценками влияет на сравнение систем?

Человеческие суждения и предсказания судьи анализируются отдельно.

Как сформирован ручной пул

Пулинг: объединение результатов нескольких источников



Пул обогащён с помощью известного ответа; это не случайная выборка корпуса.

Что измеряет NDCG@10

Релевантные ответы ближе к началу выдачи получают больший вес

Позиция в выдаче	1	2	3
Вес релевантного ответа	1,00	0,63	0,50

NDCG@10 = взвешенная релевантность / идеальная выдача

Разметка меняет оценку; поисковая выдача остаётся прежней

Учебный пример весов 1 / $\log_2$(позиция + 1). Для сравнения используется общий идеал.

Доразметка раскрывает пропущенные ответы

Релевантных фрагментов на запрос в тех же ручных пулах

1,05 → **17,47**

Исходные оценки

1 243 релевантные пары

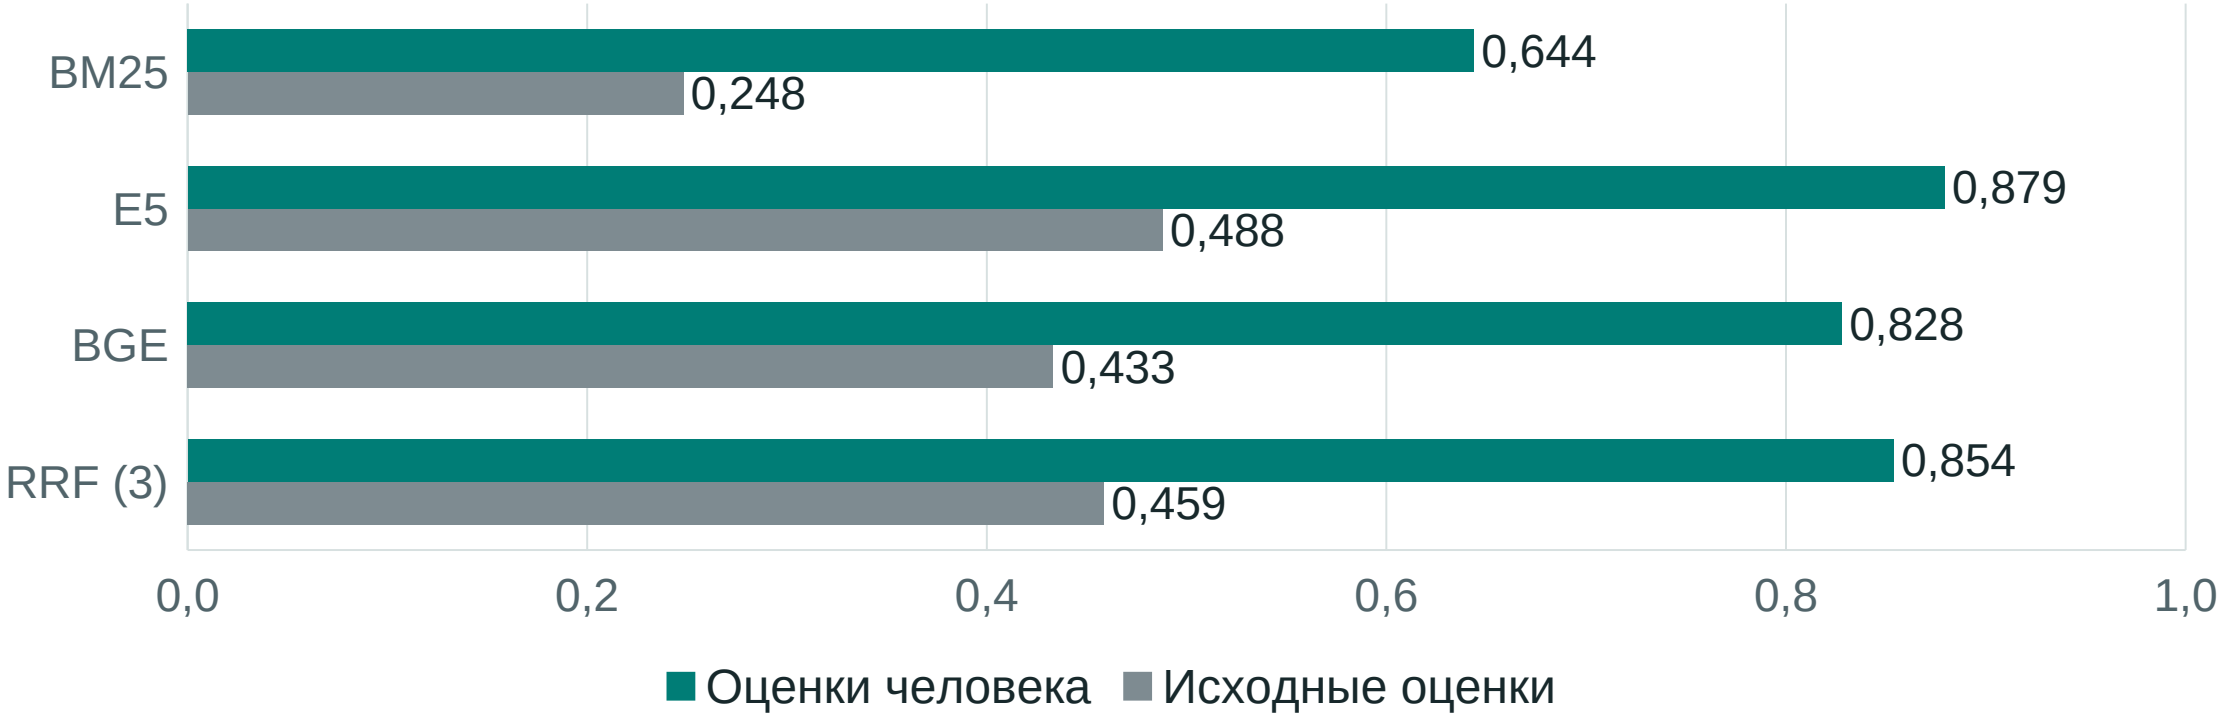
После доразметки

20 597 релевантных пар

1 179 запросов. Пулы кандидатов и порядок поисковой выдачи неизменны.

Выдача та же. Измеренная оценка выше

Бинарная NDCG@10 внутри пулов · 1 179 запросов

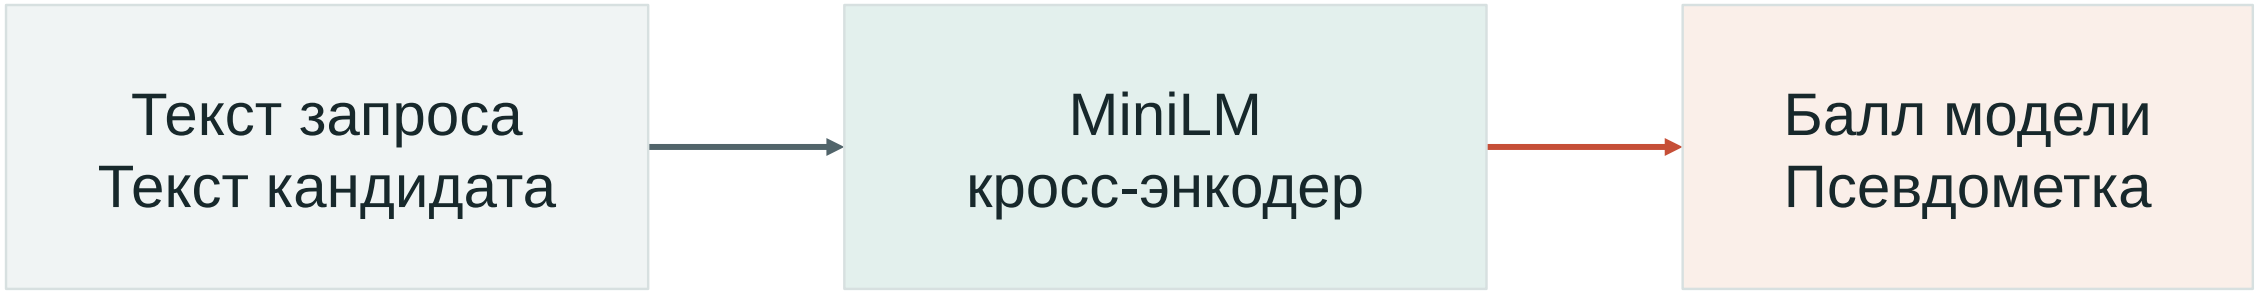


Изменение E5: +0,391 95%-ный ДИ [0,365; 0,417]

NDCG@10 внутри пулов. RRF объединяет ранги BM25, E5 и BGE; это не новый поиск.

Зачем нужна модель-судья

Ручные оценки позволяют обучить масштабируемый разметчик



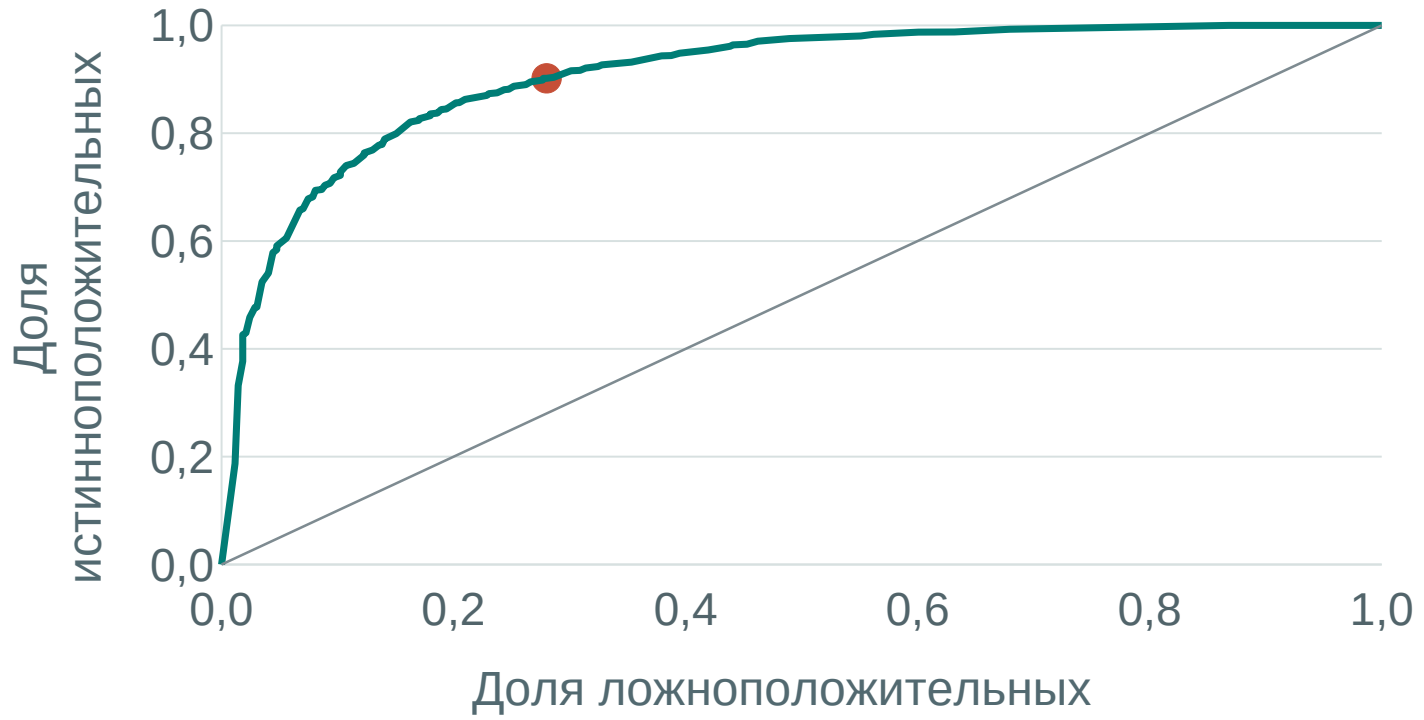
Совместная обработка текстов

Нет эталонного ответа, рангов и баллов других моделей

Судья создаёт псевдометки и не заменяет поисковые системы.

Проверка судьи на отложенных запросах

Разбиение по запросам: 825 обучение / 177 валидация / 177 тест



0,907

ROC-AUC

0,875

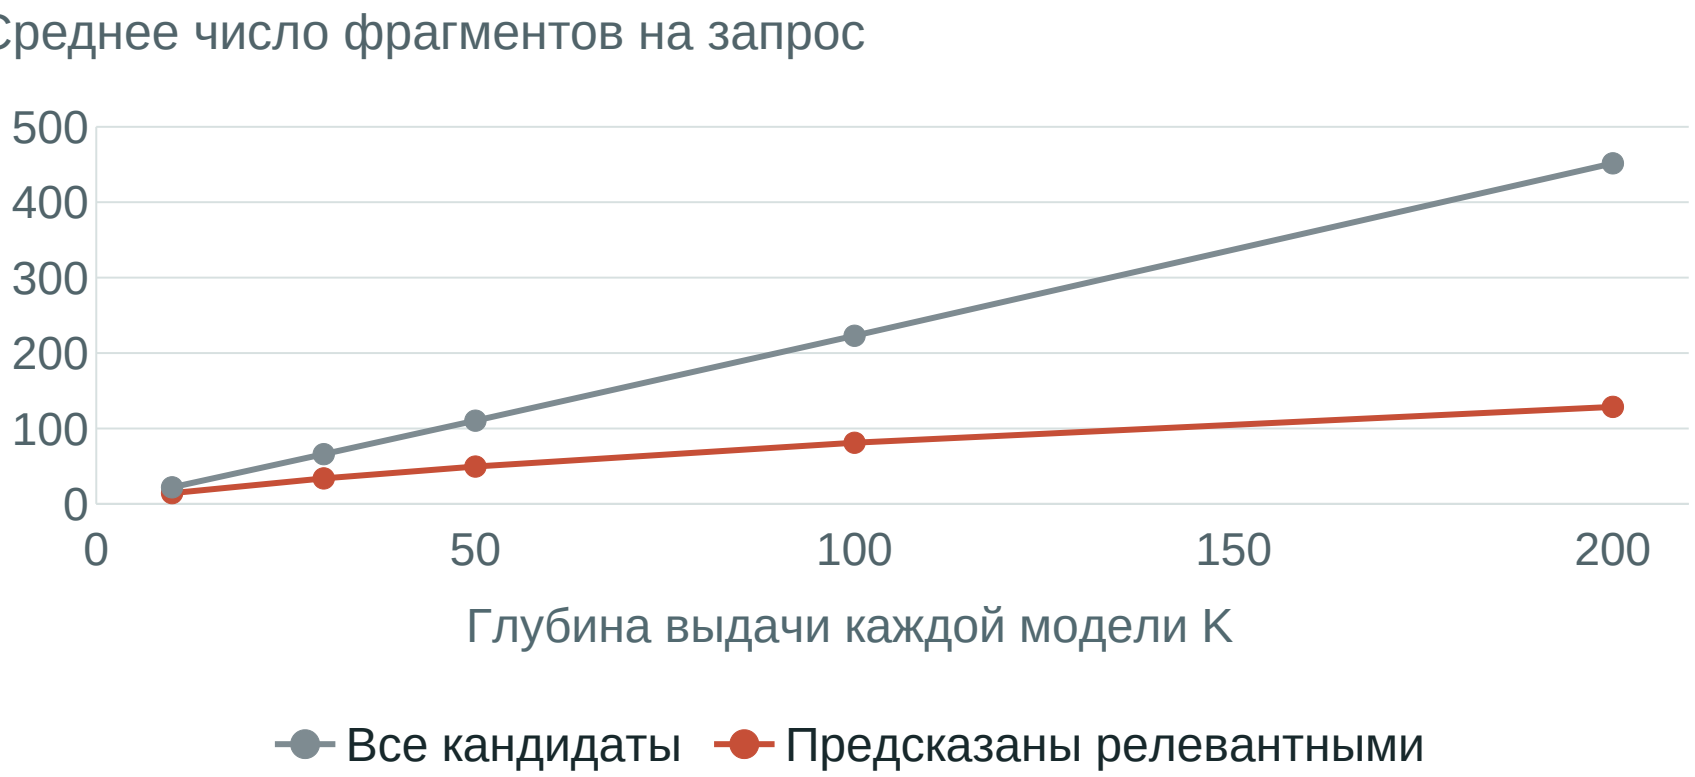
F1 при выбранном пороге

Тест: 5 002 пары · precision 0,851 · recall 0,902

Точка: порог по валидации. Глубокие пулы не имеют независимой ручной проверки.

Глубина пула меняет число псевдометок

K: сколько результатов каждой модели получит оценку судьи



451,5

кандидата

128,6

по судье
при K = 200

101 093 запроса, включая пулы без положительных меток. Судья и порог неизменны.

Глубина пула и глубина RRF меняются вместе

K: документы для оценки L: документы для слияния рангов

L = K: это совместное изменение двух параметров



K = 200: +0,0088 NDCG@10, небольшой абсолютный выигрыш

95%-ный парный ДИ [0,0082; 0,0095]. Ошибки и неопределённость судьи не учтены.
Статистическая различимость не устанавливает полезность для пользователя.

Ключевой опыт: выдача зафиксирована

L = 200. У обеих систем один и тот же топ-10 при любом K

Меняются только доступные оценки релевантности



14,4%

пар из топ-10 RRF вне оценочного пула при K = 10

Топ-10 E5 уже целиком внутри пула

K = 10: −0,0661

K = 30: +0,0080

Разность RRF − E5 по псевдометкам. Расширение пула меняет покрытие и нормировку.

Что проверено, а что ещё нет

Проверки устойчивости

1 156 запросов

После исключения 23 проблемных:
порядок систем сохранён

99 914 запросов

Без всех ручных запросов:
знаки различий RRF − E5 сохранены

Границы выводов

Ручной пул обогащён
известным ответом

Согласие разметчиков
не измерено

Один судья; глубокие пулы
не проверены людьми

Переносимость на другие модели, языки и домены требует отдельного эксперимента.

Главные выводы

Ручная доразметка

E5: 0,488 → 0,879

Ранжирование неизменно; оценка по более полным меткам выше

Оценка по псевдометкам

Покрытие пула может поменять порядок систем

Вместе с метрикой нужны источник меток, состав пула и настройки RRF

Далее: более сильные судьи и независимая ручная проверка

NDCG@10 и эффект доразметки

Парное изменение: ручные оценки минус исходные

Система	После − до	95%-ный парный ДИ
BM25	+0,396	0,372 ... 0,419
E5	+0,391	0,365 ... 0,417
BGE	+0,395	0,369 ... 0,419
RRF (3)	+0,395	0,371 ... 0,419

95%-ные ДИ: 5 000 парных bootstrap-выборок. $p < 0{,}001$: sign-flip тест.
Бинарный gain, общий IDCG по пулу; нулевые запросы остаются в среднем.

Проверка судьи и ошибки

Обучение

825

Валидация

177

Тест

177

Метка в тесте	Прогноз: нет	Прогноз: да
Отрицательная	1 300	506
Положительная	314	2 882

Точность 0,851 **Полнота 0,902** **F1 0,875**

5 002 пары: 6 неясных меток кодируются нулём, у 1 записи пустой текст.

Результаты при разной глубине пула

K	Кандидатов на запрос	Релевантных по судье на запрос	E5 NDCG@10	RRF L=K NDCG@10	RRF L=200 NDCG@10
10	21,9	14,2	0,871	0,852	0,805
30	65,8	33,7	0,851	0,862	0,859
50	110,4	49,4	0,847	0,856	0,856
100	222,9	81,0	0,844	0,851	0,853
200	451,5	128,6	0,842	0,850	0,850

При K = 200 RRF против E5: 26 241 победа / 21 042 поражения / 53 810 равенств.
Псевдометки одного судьи. Все 101 093 запроса остаются в среднем.

Чувствительность к исключению запросов

NDCG@10 по ручным оценкам

Система	Все 1 179 запросов	1 156 после исключения
BM25	0,644	0,644
E5	0,879	0,879
BGE	0,828	0,828
RRF (3)	0,854	0,855

Большой набор без ручных запросов: N = 99 914

При K = 200: RRF − E5 = +0,00877

Проверки исключением не заменяют независимую ручную оценку.

Протокол уточнённого расчёта

Правило	Применение в докладе
Состав запросов	Один и тот же набор для всех сравниваемых систем
Релевантность	Бинарная: ручные категории 1 и 2 положительные
Нормировка	Общий IDCG по пулу; при IDCG = 0 метрика равна 0
Нет оценки	Нулевой вклад без удаления позиции из выдачи
Слияние RRF	Константа 60; глубины входов L = K и L = 200

Модели: BM25 · e5-small-v2 · bge-small-en-v1.5

Уточнённые числа и вывод о RRF отличаются от редакторской версии рукописи.

Судья как переранжировщик

177 тестовых запросов · переранжирование кандидатов ручного пула

0,512

NDCG@10
по исходным меткам

0,938

NDCG@10
по человеческим меткам

Отобранный пул, не поиск по полному корпусу

Нельзя напрямую сравнивать с другими моделями на всех 1 179 запросах.