Текст выступления DAMDID 2026

Доразметка и контролируемые пулы кандидатов

Основной доклад: слайды 1-20. Резервные слайды 21-26 предназначены для ответов на вопросы. Временные отметки дают ориентир для репетиции; паузы для разбора графиков можно увеличить в пределах отведенного времени.

Слайд 1 Доразметка и контролируемые пулы кандидатов

0:00-0:35

углубленной доразметке MS MARCO и оценке поиска на контролируемых пулах

Главный вопрос работы: насколько оценка поисковой системы зависит от того, какие фрагменты текста получили оценку релевантности? Чтобы разобраться в этом, сначала поясню, почему для исследования мы выбрали именно MS MARCO.

Слайд 2 Наборы данных для оценки поиска

0:35-1:25

Для оценки поиска существуют разные наборы данных. В Natural Questions используются реальные запросы Google и ответы в статьях Википедии. BEIR объединяет разные задачи и предметные области, чтобы проверять переносимость поисковых методов.

Мы выбрали MS MARCO. Он основан на реальных запросах Bing и содержит открытые тексты веб-фрагментов. Для нашей задачи особенно важна разреженность оценок релевантности: исходная разметка может не охватывать все подходящие ответы. Это позволяет исследовать, как дополнительная разметка меняет оценку поиска. При этом MS MARCO не представляет все поисковые сценарии, поэтому перенос наших выводов на другие коллекции требует отдельной проверки.

Слайд 3 Близкие результаты ведущих систем

1:25-2:25

Посмотрим на внешний ориентир: исторический срез официальной таблицы MS MARCO на ноябрь 2022 года. Здесь четыре ведущие системы с опубликованными названиями, все в одной постановке полного поиска и на одном закрытом тестовом наборе. Их MRR на первых десяти позициях лежит в диапазоне от 0,436 до 0,450. Эта метрика усредняет обратную позицию первого найденного релевантного ответа в первой десятке.

Размах опубликованных оценок составляет 0,014. Значения близки, но это еще не доказывает ни равенство систем, ни неполноту разметки. Мы задаем отдельный вопрос: насколько сравнение зависит от того, какие ответы вообще оценены? Следующий пример показывает проблему, которую мы исследуем. А в собственных экспериментах далее используем другую метрику, NDCG,

рассчитанную внутри размеченных пулов. Напрямую сравнивать ее с этой таблицей нельзя.

Слайд 4 Релевантный ответ без оценки

2:25-3:20

В этом примере запрос звучит так: что вызывает повышение температуры кипения? Первый фрагмент говорит о добавлении соли и отмечен как релевантный в исходной разметке. Второй объясняет роль нелетучего растворенного вещества. Человек тоже считает его релевантным, однако в исходной разметке оценки для него нет. Третий фрагмент сообщает температуру кипения ацетона, но не отвечает на вопрос о причине ее повышения.

Оценки релевантности обычно называют qrels, от английского query relevance judgments. Это оценки того, насколько текст соответствует запросу. В нашем расчете метрики неразмеченный фрагмент дает нулевой вклад. Получается, система может найти полезный ответ, но не получить за него баллов. Отсутствие оценки не означает нерелевантность. Именно эту проблему мы исследуем.

Слайд 5 Данные для ручной доразметки

3:20-4:05

Сначала рассмотрим человеческие оценки. В англоязычном корпусе MS MARCO около 8,84 миллиона фрагментов. Стандартная оценочная подвыборка dev/small содержит 6 980 запросов и 7 437 исходных положительных пар. Пара здесь означает один запрос и один фрагмент, связанный с ним оценкой релевантности.

Из dev/small взяты 1 179 запросов для расширенной ручной разметки. Для них оценены 33 667 различных пар. Под углубленной доразметкой мы понимаем оценку нескольких кандидатов для каждого запроса внутри заданного пула. Речь идет об охвате разметки, а не о глубине нейросети или полной разметке всего корпуса.

Слайд 6 Разметка с известным релевантным ответом

4:05-5:05

Для подготовки ручной выборки мы применили пулинг: объединили списки кандидатов и удалили дубликаты. BM25 ищет по лексическим совпадениям. E5 и BGE используют плотные векторные представления: запрос и фрагмент кодируются отдельно. Каждый сохраненный список, полученный поиском по запросу, добавляет в пул десять результатов.

Пул расширяют дополнительные способы отбора, в том числе поиск похожих фрагментов по E5 относительно заранее известного релевантного ответа. Разметчик также видит запрос, проверяемый фрагмент и этот ответ. Это разметка с опорой на эталон: она использует сведения, которых нет у обычной поисковой системы, получающей только запрос.

В среднем в пуле около 28,6 кандидата на запрос. Они отобраны целенаправленно и не являются случайной выборкой из корпуса. Это важно помнить, когда мы говорим о большом числе найденных релевантных фрагментов.

Слайд 7 Больше оценок в тех же пулах

5:05-6:00

В этих же пулах исходные qrels содержат 1243 пары с положительной оценкой. После расширенной ручной разметки таких пар становится 20 597. Среднее число фрагментов, признанных релевантными одному запросу, увеличивается с 1,05 до 17,47.

Это не значит, что исходные положительные оценки ошибочны. Просто многие другие подходящие ответы оставались без оценки. Вместе с тем наблюдаемый рост относится именно к отобранным пулам. По нему нельзя судить о количестве всех релевантных фрагментов в коллекции.

Теперь сравним оценки поисковых систем по двум вариантам разметки. Запросы, пулы кандидатов и порядок результатов поиска остаются прежними. Меняется только разметка релевантности. Так мы можем увидеть ее влияние на измеряемое качество при неизменной выдаче.

Слайд 8 Доразметка меняет оценку NDCG@10

6:00-7:20

Качество ранжирования мы измеряем с помощью NDCG на первых десяти позициях. Метрика дает больший вес релевантным фрагментам ближе к началу выдачи и нормирует результат относительно идеального порядка. Для одного запроса и одного набора меток знаменатель, соответствующий идеальной выдаче, одинаков у всех систем.

В сравнение включен и RRF, метод слияния по обратным рангам. Он объединяет списки BM25, E5 и BGE, используя позиции результатов, а не исходные численные оценки этих моделей.

Оранжевые столбцы соответствуют исходным qrels, а зеленые показывают результаты по ручной разметке. Среднее качество растет у всех четырех систем. У E5 значение NDCG увеличивается с 0,488 до 0,879. Средний прирост в парном сравнении составляет около 0,391; под графиком приведен 95-процентный доверительный интервал этого прироста.

Здесь изменилась оценка качества благодаря более полной разметке. Сами поисковые системы мы не улучшали и не переобучали. Их порядок остается прежним: E5, RRF, BGE и BM25. Это результаты внутри размеченных пулов, а не показатели поиска по всему корпусу для общей таблицы лидеров.

Слайд 9 Модель-судья для больших пулов

7:20-8:25

Человеческие оценки позволили измерить эффект доразметки. Но проверять вручную гораздо более крупные пулы дорого. Поэтому мы дообучили компактный кросс-энкодер MiniLM на этих оценках и используем его как модель-судью. Он предсказывает релевантность пары из запроса и фрагмента. Такие предсказания называем псевдометками, чтобы отличать их от человеческих оценок.

Кросс-энкодер обрабатывает запрос и проверяемый фрагмент совместно. Этим он отличается от E5 и BGE, которые строят отдельные представления запроса и

текста. На вход нашей модели-судьи поступают только эти два текста. Ни известного релевантного ответа, ни позиций в выдаче, ни оценок других моделей она не получает.

Ручная разметка нужна и для дообучения судьи, и для проверки его ошибок на отложенных запросах. Поисковые модели при этом сохраняют свою роль: они находят кандидатов, которых затем оценивает судья. Сначала покажу, насколько его предсказания согласуются с человеческими оценками.

Слайд 10 Согласие судьи с ручной разметкой

8:25-9:25

Всю ручную подвыборку разделили по запросам: 825 для дообучения, 177 для валидации и 177 для теста. Все пары одного запроса остаются в одной части. Это наше внутреннее разбиение для судьи внутри dev/small, а не исходные train и test всего MS MARCO.

На валидационной части выбрали порог минус 0,2187. Если выходной балл судьи не ниже этого порога, присваиваем положительную псевдометку. Отрицательный порог допустим: модель выдает балл, а не вероятность. После выбора порога его фиксируем.

На тестовых 177 запросах и 5 002 парах площадь под ROC-кривой составляет 0,907, а F1 при выбранном пороге равна 0,875. Точность составляет 0,851, полнота 0,902. Это согласие с человеческими оценками в ручных пулах. Проверка не гарантирует такого же качества на более глубоких пулах.

Слайд 11 Полная dev-часть для масштабной оценки

9:25-10:20

Теперь переходим от ручной подвыборки к полной dev-части MS MARCO Passage Ranking. Она содержит 101 093 запроса. Для каждого запроса поисковые модели заранее нашли фрагменты-кандидаты, а обученный судья оценивает их релевантность. Это число запросов; фрагментов и пар «запрос-фрагмент» намного больше.

Внутри полной dev-части есть стандартная оценочная подвыборка dev/small из 6 980 запросов. Из нее взяты наши 1 179 запросов с расширенной ручной разметкой. Судью дообучали только на обучающей части этой ручной подвыборки. Теперь используем его предсказания для кандидатов по всем 101 093 запросам. Человеческими метками эти предсказания не подменяем. Отдельно проверим, сохраняются ли результаты без запросов из ручной подвыборки.

Слайд 12 Пулы кандидатов для модели-судьи

10:20-11:05

Пул для судьи строится так. Для каждого запроса берем первые K результатов BM25, E5 и BGE, объединяем их и удаляем повторяющиеся фрагменты. Затем судья получает каждую пару из запроса и кандидата и присваивает ей псевдометку.

K называют глубиной пула: это число результатов от одного метода до объединения. Например, при K, равном десяти, три списка дают не более тридцати

уникальных кандидатов. После удаления повторов их обычно меньше. Мы проверяем K от десяти до двухсот. Модель и порог минус 0,2187 остаются прежними, меняется только набор оцениваемых кандидатов.

Слайд 13 Размер пула и предсказанная релевантность

11:05-11:45

При увеличении K с десяти до двухсот средний размер пула растет примерно с 22 до 452 кандидатов. Число фрагментов, которые модель считает релевантными, в среднем увеличивается примерно с 14 до 129. Эти средние рассчитаны по всем запросам, включая запросы без единого положительного предсказания.

Рост зависит от того, какой пул мы выбрали для оценки. Эти числа нельзя трактовать как количество всех подходящих ответов в корпусе. Далее посмотрим, как изменение охвата разметки влияет на сравнение поисковых систем.

Слайд 14 Зачем объединять результаты с помощью RRF

11:45-13:05

Зачем здесь RRF? Лексический поиск BM25 и векторные модели E5 и BGE могут находить разные полезные фрагменты. Мы хотим проверить, помогает ли простое объединение их выдач, и насколько ответ зависит от полноты разметки.

RRF означает слияние по обратным рангам. Для каждого фрагмента смотрим его место в выдаче BM25, E5 и BGE. Каждый список, в котором он найден, добавляет один, деленный на шестьдесят плюс место. Эти вклады складываем и сортируем фрагменты по сумме. У трех систем одинаковый вес.

Например, фрагмент попал в первые L результатов E5 и BGE, но не попал в первые L результатов BM25. Тогда складываются только два вклада: от E5 и BGE. BM25 этому фрагменту ничего не добавляет. Фрагмент при этом остается кандидатом для итоговой выдачи RRF.

Поэтому RRF объединяет позиции, а не усредняет исходные баллы трех моделей. Это удобно, потому что их баллы имеют разные шкалы. На выходе получаем один итоговый ранжированный список. Оценки судьи не участвуют в его построении: они нужны для последующего сравнения качества.

Слайд 15 Меняются пул и входные списки RRF

13:05-14:35

Здесь мы сравниваем RRF с E5 и различаем две глубины. K задает число результатов от каждой системы в пуле для разметки. L задает число результатов, поступающих на слияние рангов. В этой конфигурации обе величины растут вместе: L равно K.

Почему берем больше десяти результатов, хотя считаем NDCG по первой десятке? Потому что десять в NDCG относится к итоговому списку после слияния. Фрагмент, стоящий одиннадцатым у всех трех систем, при L, равном десяти, вообще не попадет в RRF. При L не меньше одиннадцати он получит сразу три вклада и может войти в итоговый топ-10. Поэтому более глубокие входные списки способны изменить и состав первой десятки, и порядок внутри нее.

По горизонтальной оси отложена разность двух значений NDCG@10: значение для RRF минус значение для E5. Значения слева от нуля означают преимущество E5, справа от нуля преимущество RRF. При K, равном десяти, RRF уступает. На четырех больших глубинах разность небольшая, но положительная. При глубине двести она составляет около 0,0088.

Горизонтальные отрезки показывают 95-процентные доверительные интервалы разности. Здесь одновременно меняются и охват разметки, и входные списки для слияния. Чтобы выделить влияние охвата, дальше зафиксируем ранжирование.

Слайд 16 Покрытие разметкой меняет сравнение

14:35-16:00

Теперь RRF всегда использует первые двести результатов каждого источника. Глубина L фиксирована, а первые десять результатов RRF и E5 не меняются. Варьируется только K, то есть глубина пула, для которого получаем оценки релевантности.

Даже при такой неизменной выдаче преимущество переходит от одной системы к другой. Из NDCG@10 для RRF вычитаем NDCG@10 для E5. Получаем примерно минус 0,066 при K, равном десяти, и плюс 0,008 при K, равном тридцати. Отрицательная разность означает преимущество E5, положительная преимущество RRF.

При K, равном десяти, 14,4 процента пар из итогового топ-10 RRF лежат за пределами пула с оценками. При расчете метрики они дают нулевой вклад. Но отсутствие оценки не означает, что фрагмент нерелевантен: в этом пуле мы его просто не оценивали. Разметка более глубокого пула позволяет проверить и такие фрагменты.

Более широкий пул дает оценки для большего числа найденных фрагментов и может изменить знаменатель, соответствующий идеальному ранжированию. Основной результат: измеряемый порядок систем способен измениться без изменения их выдачи. При этом вывод по-прежнему зависит от псевдометок одной модели-судьи.

Слайд 17 Устойчивость и ограничения

16:00-17:10

В масштабном эксперименте все метки получены одним судьей. Это относится и к тем запросам, которые раньше размечал человек. Ручные ответы здесь не заменяют предсказания судьи и не дополняют их.

Однако часть этих запросов использовалась при дообучении судьи. Поэтому мы дополнительно пересчитали сравнение, исключив все 1 179 запросов ручной подвыборки. Из 101 093 осталось 99 914. На каждой проверенной глубине преимущество осталось у той же системы, что и до исключения. Это говорит об устойчивости сравнения к такому пересечению, но не заменяет независимый тест судьи.

Ограничения сохраняются. Человек видел известный релевантный ответ, а судья получает только запрос и кандидата. Согласие между разметчиками не измерялось. Более глубокие пулы не проходили независимую ручную проверку.

Наши численные выводы относятся к выбранным англоязычным пулам MS MARCO. Их перенос на другие языки, предметные области и поисковые сервисы еще предстоит проверить.

Слайд 18 Полнота разметки влияет на сравнение систем

17:10-18:35

Ручная доразметка существенно меняет оценку качества поиска. В наших ручных пулах NDCG@10 системы E5 увеличивается с 0,488 до 0,879 при неизменной выдаче. Система уже находила полезные фрагменты, но неполная исходная разметка не давала ей за них баллы.

В масштабном эксперименте при той же выдаче меняется даже победитель сравнения: на малом пуле E5 опережает RRF, а при расширении пула вперед выходит RRF. Практический смысл в том, что выбор лучшей системы зависит от того, какие найденные фрагменты получили оценки. Различие возникает без переобучения поисковых моделей.

Близкие метрики при неполной разметке сами по себе не доказывают одинаковое качество систем. Но и утверждать, что мы установили истинного лидера, пока нельзя: масштабное сравнение опирается на оценки одного судьи. Поэтому при сравнении систем нужно проверять, как вывод зависит от охвата разметки и источника оценок.

Следующий шаг состоит в улучшении автоматической доразметки. Планируем сравнить более сильные модели-судьи и проверить вариант, который получает запрос, известный релевантный ответ и фрагмент-кандидат. Качество такой доразметки нужно подтвердить независимыми человеческими оценками, в том числе на глубоких пулах.

Слайд 19 Литература и ресурсы

18:35-18:45

На слайде приведены основные работы и ссылки на использованные методы и наборы данных.

Слайд 20 Спасибо за внимание

18:45-19:00

Ответы на возможные вопросы

Пояснения к данным, модели-судье и сравнению поисковых систем. Указаны слайды, которые можно показать при ответе.

Почему именно 101 093 запроса, а не 140 тысяч?

Резервный слайд 21

101 093 запроса содержит полная dev-часть MS MARCO Passage Ranking v1. Мы использовали именно этот набор, без отбора до 101 тысячи из более крупной выборки. Его стандартная оценочная подвыборка dev/small содержит 6 980 запросов. Число около 140 тысяч к этому набору не относится.

101 093, 6 980 и 1 179: как эти числа связаны?

Резервный слайд 21

101 093 запроса входят в полную dev-часть. dev/small содержит 6 980 из них и исходные оценки релевантности для стандартного оценивания. Ручная подвыборка содержит 1 179 запросов из dev/small. Один запрос может иметь много кандидатов, поэтому в ручной части 33 667 пар. Размер корпуса другой: 8 841 823 фрагмента.

Мы учились и тестировались на dev MS MARCO?

Резервный слайд 23

Дообучение нашего судьи и его локальная проверка выполнялись на ручной подвыборке из dev/small. Мы отдельно разделили ее на 825 обучающих, 177 валидационных и 177 тестовых запросов. Это внутренние части эксперимента, а не официальный закрытый test MS MARCO. Исходный MiniLM уже был предварительно обучен; проверка исключает пересечение запросов в нашем дообучении, но сама по себе не доказывает отсутствие пересечений с его предобучением.

Почему для ручной разметки выбраны именно 1 179 запросов?

Резервный слайд 21

Это объем подготовленной ручной подвыборки, на которой выполнен эксперимент. Ее принадлежность dev/small проверена по идентификаторам. Мы не рассматриваем ее как случайную или репрезентативную выборку из всего MS MARCO. Выводы ручного эксперимента относятся к этой подвыборке и ее кандидатным пулам.

Что видел человек и что получает модель-судья?

Резервный слайд 26

Человек видел запрос, оцениваемый фрагмент и известный релевантный ответ. Подготовка ручных кандидатов также использовала сходство E5 с этим ответом. Судья получает только тексты запроса и кандидата. Он не получает известного ответа, позиций, баллов BM25, E5 или BGE и заранее рассчитанных эмбеддингов. Добавление эталонного ответа ко входу судьи предложено как следующий эксперимент.

Судья может быть слабее поисковых моделей. Зачем тогда он нужен?

Резервный слайд 23

Судья нужен как доступный способ получить много дополнительных оценок и исследовать зависимость метрик от охвата. Он не заменяет поисковые системы и не считается безошибочным эталоном. BM25, E5 и BGE по-прежнему находят и ранжируют кандидатов. На ручных данных их сравнение опирается на человеческие оценки. Масштабные выводы с MiniLM условны и требуют проверки более сильными судьями и независимой ручной разметкой.

Почему выбран MiniLM? Сравнивали ли другие cross-encoder?

Резервный слайд 26

Это компактная исходная модель cross-encoder/ms-marco-MiniLM-L6-v2, пригодная для оценки большого числа пар. В представленном эксперименте ее дообучили на ручных оценках. Сравнения нескольких судей и модели со входом «запрос, эталонный ответ, кандидат» пока не выполнены. Результаты таких сравнений не заявляются.

Почему порог отрицательный и как его выбрали?

Резервный слайд 23

Используется ненормированный выходной балл модели. Его шкала допускает отрицательные числа и не совпадает со шкалой вероятностей от нуля до единицы. Порог −0,2187178284 выбрали на 177 валидационных запросах и затем не меняли ни для теста, ни для разных K. На слайдах значение округлено до −0,2187. Тестовая F1 при этом пороге равна 0,875.

Насколько часто судья ошибается?

Резервный слайд 23

На 5 002 тестовых парах получены 2 882 верных положительных и 1 300 верных отрицательных решения, 506 ложноположительных и 314 ложноотрицательных. Точность 0,851 означает, что около 85% положительных предсказаний совпали с целевыми ручными метками на этом тесте. Эти доли нельзя автоматически переносить на все более глубокие пулы.

Что такое K и чем оно отличается от L?

Резервный слайд 24

K определяет, сколько результатов от каждой системы попадает в пул разметки. L определяет, сколько результатов от каждой системы поступает на слияние RRF. В первом сравнении L равно K, поэтому меняются и пул, и итоговое ранжирование. В контрольном сравнении L всегда равно 200: выдача фиксирована, меняется только пул с оценками. Повторяющиеся кандидаты учитываются один раз.

У каждого из 101 093 запросов есть все три поисковых списка?

Резервный слайд 21

Для E5 и BGE сохранены выдачи для всех 101 093 запросов. У BM25 нет выдач для трех запросов, а некоторые списки короче заданной глубины. Используем доступные результаты. Если фрагмент не попал в первые L результатов одной системы, она не добавляет ему балл RRF, но другие системы могут его добавить.

RRF усредняет предсказания моделей или ответы судьи?

Резервный слайд 24

Нет. RRF суммирует величины, зависящие от места документа в списках BM25, E5 и BGE: 1/(60 + место). Веса источников одинаковы. Сырые поисковые баллы и оценки судьи в формулу не входят. Например, первое место у любого источника дает вклад 1/61. Судья используется отдельно для оценки полученного списка.

Если NDCG выросла, значит поиск стал лучше?

Резервный слайд 22

В ручном сравнении поисковая выдача не менялась. Изменились метки, по которым мы ее оцениваем: ранее неоцененные полезные ответы стали давать вклад в метрику. Поэтому выросла измеренная оценка качества, а не возможности самой поисковой модели. NDCG@10 учитывает релевантность в первой десятке с большим весом верхних позиций и нормирует ее относительно идеальной выдачи.

В масштабном эксперименте смешаны оценки человека и судьи?

Слайд 17

Нет. Все масштабные метрики рассчитаны по псевдометкам одного судьи. Это касается и 1 179 запросов, для которых есть ручная разметка. В этой части расчета ручные метки не подставлялись вместо предсказаний и не объединялись с ними. Сравнение исходных, человеческих и машинных меток относится к отдельному ручному эксперименту.

Полная dev-часть включает запросы, участвовавшие в дообучении судьи. Поэтому дополнительно исключили все 1 179 ручных запросов, включая обучающие, валидационные и тестовые, и пересчитали метрики на оставшихся 99 914. Для каждого K знак разности RRF и E5 сохранился. Это проверка устойчивости сравнения. Все 101 093 запроса нельзя называть независимым тестом судьи.

Значит, на каждый запрос есть 17 или 129 правильных ответов?

Резервный слайд 24

17,47 относится к среднему числу положительных человеческих оценок внутри ручных пулов. 128,6 относится к положительным предсказаниям одного судьи при K = 200 на полной dev-части. Пулы целенаправленно отобраны поисковыми методами. Ни одно число не оценивает полное количество релевантных ответов во всем корпусе.

Какие выводы можно переносить на другие данные?

Слайд 17

Эксперимент показывает, что неполные оценки и выбранный пул могут существенно влиять на измеряемое качество. Конкретные численные эффекты получены на англоязычных пулах MS MARCO. Их перенос на другие языки, предметные области и поисковые сервисы нужно проверять отдельно.

Зачем L больше 10, если метрика NDCG@10?

Слайд 15

L ограничивает входные списки BM25, E5 и BGE до слияния. NDCG@10 оценивает первые десять позиций уже получившегося списка RRF. Это разные этапы.

Условный пример: в первых десяти результатах трех систем нет общих фрагментов, но один и тот же фрагмент стоит одиннадцатым у всех трех. При L = 10 его нет среди кандидатов RRF. При L = 11 его сумма равна 3/(60 + 11), примерно 0,0423. У фрагмента, который стоит первым только в одном списке, сумма 1/(60 + 1), примерно 0,0164. Общий фрагмент становится первым в RRF. Поэтому L > 10 может менять итоговый топ-10. При этом дальнейшее увеличение L не обязано менять выдачу на каждом запросе.

Что именно не так с 23 запросами ручной подвыборки?

Резервный слайд 25

В исходных записях нашли 29 пар с кодами меток вне принятой шкалы 0/1/2: 26 меток со значением 3, две со значением 20 и одну со значением 22. Эти записи относятся к 18 запросам. Значение таких кодов не установлено, поэтому их нельзя произвольно считать подтвержденными положительными или отрицательными оценками.

Еще у пяти других запросов обнаружили по одному кандидату с пустым текстом. Всего затронуты 23 запроса. В дополнительном расчете исключили эти запросы целиком, осталось 1 156. Порядок поисковых систем по человеческим оценкам не изменился. В основном расчете нестандартные метки не считались подтвержденными положительными оценками и давали нулевой вклад. Исключение служит проверкой чувствительности результата, а не новой разметкой.

Неоцененный фрагмент считается нерелевантным?

Слайд 16

При расчете NDCG фрагмент без оценки в текущем пуле дает нулевой вклад. Это правило подсчета при неполной разметке, а не установленная нерелевантность. Часть таких фрагментов может оказаться полезной после оценки. При K = 10 за пределами пула лежат 14,4% пар из топ-10 RRF, построенного из списков глубины L = 200.

Что означает ДИ 95% и учитывает ли он ошибки судьи?

Слайд 15

ДИ означает доверительный интервал. На графике показан парный бутстрэп по запросам: многократно набираем запросы с возвращением и каждый раз считаем среднюю разность метрик двух систем. Парность означает, что в каждом повторе сравниваем системы на одних и тех же запросах. Уровень доверия составляет 95%.

В масштабном эксперименте модель-судья и ее предсказания при этом фиксированы. Интервал показывает вариативность сравнения по запросам, но не включает ошибки псевдоразметки и неопределенность обучения судьи. Узкий интервал не подтверждает правильность каждой метки. Для этого нужна независимая человеческая проверка.

Почему важно, что RRF и E5 меняются местами?

Слайд 16

По метрикам часто выбирают систему для дальнейшего использования. Если победитель меняется только потому, что оценили больше найденных фрагментов, вывод зависит не только от поисковой системы, но и от покрытия разметкой. В нашем контролируемом сравнении обе выдачи фиксированы: при K = 10 преимущество у E5, а при K = 30 у RRF.

Это показывает чувствительность сравнения к пулу оценок. Само по себе такое переставление не доказывает, что RRF объективно лучше, поскольку оценки дает один судья. Также отсюда нельзя сделать вывод о существенных различиях всех современных SOTA-моделей. Проверяемый вывод уже: близкие показатели на неполной разметке не достаточны, чтобы считать системы равноценными. Для надежного выбора нужна более полная и независимо проверенная разметка.