Текст выступления DAMDID 2026

Доразметка и контролируемые пулы кандидатов

Основной доклад: слайды 1–20, ориентировочно 16–18 минут. Резервные слайды 21–26 предназначены для ответов на вопросы.

Слайд 1 Доразметка и контролируемые пулы кандидатов

0:00–0:25

углублённой доразметке MS MARCO и оценке поиска на контролируемых пулах

Главный вопрос работы: насколько оценка поисковой системы зависит от того, какие фрагменты текста получили оценку релевантности? Чтобы разобраться в этом, сначала поясню, почему для исследования мы выбрали именно MS MARCO.

Слайд 2 Наборы данных для оценки поиска

0:25–1:05

Для оценки поиска существуют разные наборы данных. В Natural Questions используются реальные запросы Google и ответы в статьях Википедии. BEIR объединяет разные задачи и предметные области, чтобы проверять переносимость поисковых методов.

Мы выбрали MS MARCO. Он основан на реальных запросах Bing и содержит открытые тексты веб-фрагментов. Для нашей задачи особенно важна разреженность оценок релевантности: исходная разметка может не охватывать все подходящие ответы. Это позволяет исследовать, как дополнительная разметка меняет оценку поиска. При этом MS MARCO не представляет все поисковые сценарии, поэтому перенос наших выводов на другие коллекции требует отдельной проверки.

Слайд 3 Близкие результаты ведущих систем

1:05–1:50

Посмотрим на внешний ориентир: исторический срез официальной таблицы MS MARCO на ноябрь 2022 года. Здесь четыре ведущие системы с опубликованными названиями, все в одной постановке полного поиска и на одном закрытом тестовом наборе. Их MRR на первых десяти позициях лежит в диапазоне от 0,436 до 0,450. Эта метрика усредняет обратную позицию первого найденного релевантного ответа в первой десятке.

Размах опубликованных оценок составляет 0,014. Значения близки, но это ещё не доказывает ни равенство систем, ни неполноту разметки. Мы задаём отдельный вопрос: насколько сравнение зависит от того, какие ответы вообще оценены? Следующий пример показывает проблему, которую мы исследуем. А в

собственных экспериментах далее используем другую метрику, NDCG, рассчитанную внутри размеченных пулов. Напрямую сравнивать её с этой таблицей нельзя.

Слайд 4 Релевантный ответ без оценки

1:50–2:35

В этом примере запрос звучит так: что вызывает повышение температуры кипения? Первый фрагмент говорит о добавлении соли и отмечен как релевантный в исходной разметке. Второй объясняет роль нелетучего растворённого вещества. Человек тоже считает его релевантным, однако в исходной разметке оценки для него нет. Третий фрагмент сообщает температуру кипения ацетона, но не отвечает на вопрос о причине её повышения.

Оценки релевантности обычно называют qrels, от английского query relevance judgments. Это оценки того, насколько текст соответствует запросу. В нашем расчёте метрики неразмеченный фрагмент даёт нулевой вклад. Получается, система может найти полезный ответ, но не получить за него баллов. Отсутствие оценки не означает нерелевантность. Именно эту проблему мы исследуем.

Слайд 5 Данные для ручной доразметки

2:35–3:15

Сначала рассмотрим человеческие оценки. В англоязычном корпусе MS MARCO около 8,84 миллиона фрагментов. Стандартная оценочная подвыборка dev/small содержит 6 980 запросов и 7 437 исходных положительных пар. Пара здесь означает один запрос и один фрагмент, связанный с ним оценкой релевантности.

Из dev/small взяты 1 179 запросов для расширенной ручной разметки. Для них оценены 33 667 различных пар. Под углублённой доразметкой мы понимаем оценку нескольких кандидатов для каждого запроса внутри заданного пула. Речь идёт об охвате разметки, а не о глубине нейросети или полной разметке всего корпуса.

Слайд 6 Разметка с известным релевантным ответом

3:15–4:15

Для подготовки ручной выборки мы применили пулинг: объединили списки кандидатов и удалили дубликаты. BM25 ищет по лексическим совпадениям. E5 и BGE используют плотные векторные представления: запрос и фрагмент кодируются отдельно. Каждый сохранённый список, полученный поиском по запросу, добавляет в пул десять результатов.

Пул расширяют дополнительные способы отбора, в том числе поиск похожих фрагментов по E5 относительно заранее известного релевантного ответа. Разметчик также видит запрос, проверяемый фрагмент и этот ответ. Это разметка с опорой на эталон: она использует сведения, которых нет у обычной поисковой системы, получающей только запрос.

В среднем в пуле около 28,6 кандидата на запрос. Они отобраны целенаправленно и не являются случайной выборкой из корпуса. Это важно помнить, когда мы говорим о большом числе найденных релевантных фрагментов.

Слайд 7 Больше оценок в тех же пулах

4:15–4:55

В этих же пулах исходные qrels содержат 1243 пары с положительной оценкой. После расширенной ручной разметки таких пар становится 20 597. Среднее число фрагментов, признанных релевантными одному запросу, увеличивается с 1,05 до 17,47.

Это не значит, что исходные положительные оценки ошибочны. Просто многие другие подходящие ответы оставались без оценки. Вместе с тем наблюдаемый рост относится именно к отобранным пулам. По нему нельзя судить о количестве всех релевантных фрагментов в коллекции.

Теперь сравним оценки поисковых систем по двум вариантам разметки. Запросы, пулы кандидатов и порядок результатов поиска остаются прежними. Меняется только разметка релевантности. Так мы можем увидеть её влияние на измеряемое качество при неизменной выдаче.

Слайд 8 Доразметка меняет оценку NDCG@10

4:55–6:00

Качество ранжирования мы измеряем с помощью NDCG на первых десяти позициях. Метрика даёт больший вес релевантным фрагментам ближе к началу выдачи и нормирует результат относительно идеального порядка. Для одного запроса и одного набора меток знаменатель, соответствующий идеальной выдаче, одинаков у всех систем.

В сравнение включён и RRF, метод слияния по обратным рангам. Он объединяет списки BM25, E5 и BGE, используя позиции результатов, а не исходные численные оценки этих моделей.

Серые столбцы соответствуют исходным qrels, а зелёные показывают результаты по ручной разметке. Среднее качество растёт у всех четырёх систем. У E5 значение NDCG увеличивается с 0,488 до 0,879. Средний прирост в парном сравнении составляет около 0,391; доверительный интервал показан под графиком.

Здесь изменилась оценка качества благодаря более полной разметке. Сами поисковые системы мы не улучшали и не переобучали. Их порядок остаётся прежним: E5, RRF, BGE и BM25. Это результаты внутри размеченных пулов, а не показатели поиска по всему корпусу для общей таблицы лидеров.

Слайд 9 Модель-судья для больших пулов

6:00–6:55

Человеческие оценки позволили измерить эффект доразметки. Но проверять вручную гораздо более крупные пулы дорого. Поэтому мы дообучили компактный

кросс-энкодер MiniLM на этих оценках и используем его как модель-судью. Он предсказывает релевантность пары из запроса и фрагмента. Такие предсказания называем псевдометками, чтобы отличать их от человеческих оценок.

Кросс-энкодер обрабатывает запрос и проверяемый фрагмент совместно. Этим он отличается от E5 и BGE, которые строят отдельные представления запроса и текста. На вход нашей модели-судьи поступают только эти два текста. Ни известного релевантного ответа, ни позиций в выдаче, ни оценок других моделей она не получает.

Ручная разметка нужна и для дообучения судьи, и для проверки его ошибок на отложенных запросах. Поисковые модели при этом сохраняют свою роль: они находят кандидатов, которых затем оценивает судья. Сначала покажу, насколько его предсказания согласуются с человеческими оценками.

Слайд 10 Согласие судьи с ручной разметкой

6:55–7:55

Всю ручную подвыборку разделили по запросам: 825 для дообучения, 177 для валидации и 177 для теста. Все пары одного запроса остаются в одной части. Это наше внутреннее разбиение для судьи внутри dev/small, а не исходные train и test всего MS MARCO.

На валидационной части выбрали порог минус 0,2187. Если выходной балл судьи не ниже этого порога, присваиваем положительную псевдометку. Отрицательный порог допустим: модель выдаёт балл, а не вероятность. После выбора порога его фиксируем.

На тестовых 177 запросах и 5 002 парах площадь под ROC-кривой составляет 0,907, а F1 при выбранном пороге равна 0,875. Точность составляет 0,851, полнота 0,902. Это согласие с человеческими оценками в ручных пулах. Проверка не гарантирует такого же качества на более глубоких пулах.

Слайд 11 Полная dev-часть для масштабной оценки

7:55–8:35

Теперь переходим к масштабному эксперименту. Число 101 093 имеет конкретное происхождение: столько запросов содержит полная dev-часть MS MARCO Passage Ranking, файл queries.dev.tsv. Набор идентификаторов в наших результатах полностью совпадает с этим файлом. Это количество запросов, а не ответов или пар.

Важно различать полную dev-часть из 101 093 запросов и её стандартную подвыборку dev/small из 6 980. Ручная разметка охватывает 1 179 запросов из dev/small. Для полной dev-части заранее получили поисковые выдачи, а теперь применяем обученного судью к найденным кандидатам. Сам судья не обучается на всех 101 тысяче запросов.

Слайд 12 Пулы кандидатов для модели-судьи

8:35–9:20

Пул для судьи строится так. Для каждого запроса берём первые K результатов BM25, E5 и BGE, объединяем их и удаляем повторяющиеся фрагменты. Затем судья получает каждую пару из запроса и кандидата и присваивает ей псевдометку.

K называют глубиной пула: это число результатов от одного метода до объединения. Например, при K, равном десяти, три списка дают не более тридцати уникальных кандидатов. После удаления повторов их обычно меньше. Мы проверяем K от десяти до двухсот. Модель и порог минус 0,2187 остаются прежними, меняется только набор оцениваемых кандидатов.

Слайд 13 Размер пула и предсказанная релевантность

9:20–10:00

При увеличении K с десяти до двухсот средний размер пула растёт примерно с 22 до 452 кандидатов. Число фрагментов, которые модель считает релевантными, в среднем увеличивается примерно с 14 до 129. Эти средние рассчитаны по всем запросам, включая запросы без единого положительного предсказания.

Рост зависит от того, какой пул мы выбрали для оценки. Эти числа нельзя трактовать как количество всех подходящих ответов в корпусе. Далее посмотрим, как изменение охвата разметки влияет на сравнение поисковых систем.

Слайд 14 Зачем объединять результаты с помощью RRF

10:00–11:00

Зачем здесь RRF? Лексический поиск BM25 и векторные модели E5 и BGE могут находить разные полезные фрагменты. Мы хотим проверить, помогает ли простое объединение их выдач, и насколько ответ зависит от полноты разметки.

RRF означает слияние по обратным рангам. Каждый источник добавляет документу величину один, делённый на шестьдесят плюс его место в списке. Складываем эти величины для BM25, E5 и BGE и сортируем документы по сумме. У источников одинаковый вес. Если документа нет в используемом списке, вклад этого источника равен нулю.

Поэтому RRF объединяет позиции, а не усредняет исходные баллы трёх моделей. Это удобно, потому что их баллы имеют разные шкалы. На выходе получаем один итоговый ранжированный список. Оценки судьи не участвуют в его построении, они нужны для последующего сравнения качества.

Слайд 15 Меняются пул и входные списки RRF

11:00–11:55

Здесь мы сравниваем RRF с E5 и различаем две глубины. K задаёт число результатов от каждой системы в пуле для разметки. L задаёт число результатов, поступающих на слияние рангов. В этой конфигурации обе величины растут вместе: L равно K.

По горизонтальной оси отложена разность NDCG: RRF минус E5. Значения слева от нуля означают преимущество E5, справа от нуля преимущество RRF. При K,

равном десяти, RRF уступает. На четырёх больших глубинах разность небольшая, но положительная. При глубине двести она составляет около 0,0088.

Интервалы получены парным бутстрэпом по запросам. Они рассчитаны для фиксированной модели-судьи и не учитывают неопределённость её обучения и ошибки разметки. Кроме того, здесь одновременно меняются и охват, и входные списки для слияния. Чтобы яснее выделить влияние охвата, дальше зафиксируем ранжирование.

Слайд 16 Покрытие разметкой меняет сравнение

11:55–12:55

Теперь RRF всегда использует первые двести результатов каждого источника. Глубина L фиксирована, а первые десять результатов RRF и E5 не меняются. Варьируется только K, то есть глубина пула, для которого получаем оценки релевантности.

Даже при такой неизменной выдаче преимущество переходит от одной системы к другой. Разность RRF минус E5 составляет примерно минус 0,066 при K, равном десяти, и плюс 0,008 при K, равном тридцати.

Подпись справа помогает понять роль охвата. На минимальной глубине 14,4 процента пар из первых десяти результатов RRF оказываются за пределами размеченного пула. В метрике они получают нулевой вклад, поскольку не оценены. Это вовсе не означает, что все эти фрагменты релевантны.

Более широкий пул даёт оценки для большего числа найденных фрагментов и может изменить знаменатель, соответствующий идеальному ранжированию. Основной результат: измеряемый порядок систем способен измениться без изменения их выдачи. При этом вывод по-прежнему зависит от псевдометок одной модели-судьи.

Слайд 17 Устойчивость и ограничения

12:55–13:45

Мы проверили чувствительность результатов к двум исключениям. В ручном эксперименте удалили 23 запроса, для которых оставались неясности с категориями меток или встречались пустые тексты. Порядок систем не изменился. В масштабном эксперименте после исключения всех запросов с ручной разметкой остаётся 99 914 запросов. Знаки различий между RRF и E5 сохраняются на всех проверенных глубинах.

Эти проверки касаются конкретных проблем данных и пересечения двух наборов запросов, но не устраняют все возможные смещения. Ручные пулы используют информацию об эталонном ответе; согласие между разметчиками не измерялось. Масштабный эксперимент опирается на одну компактную модель-судью, а более глубокие пулы не проходили независимую ручную проверку.

Поэтому наши выводы относятся к выбранным англоязычным пулам MS MARCO. Переносимость результатов на другие языки, предметные области и поисковые сервисы ещё предстоит проверить.

Слайд 18 Полнота разметки влияет на оценку поиска

13:45–14:30

Подведу итог. Более полная ручная разметка существенно меняет оценку уже полученных результатов поиска. В наших ручных пулах NDCG системы E5 увеличивается с 0,488 до 0,879 при совершенно неизменном ранжировании.

Масштабный эксперимент показывает, что охват разметки способен даже поменять местами RRF и E5 в сравнении качества при фиксированной выдаче обеих систем. Этот результат получен с одной моделью-судьёй и зависит от её оценок.

Поэтому вместе с метрикой качества поиска нужно указывать пул разметки, источник меток и настройки слияния. На следующем этапе мы сравним более сильные модели-судьи с доступом к известному релевантному фрагменту и без него, используя независимые человеческие оценки для проверки. Этот эксперимент запланирован, но пока не выполнен.

Слайд 19 Литература и ресурсы

14:30–14:35

На слайде приведены основные работы и ссылки на использованные методы и наборы данных.

Слайд 20 Спасибо за внимание

14:35–14:45

Спасибо за внимание! Буду рад вашим вопросам.

Ответы на возможные вопросы

Развёрнутые пояснения к данным, модели-судье и сравнению поисковых систем. Номера в заголовках указывают на резервные слайды.

Почему именно 101 093 запроса, а не 140 тысяч?

Резервный слайд 21

Это полный набор запросов dev в MS MARCO Passage Ranking v1, файл queries.dev.tsv. Совпадает не только количество: множество идентификаторов в результатах эксперимента полностью совпадает с официальным файлом. Поэтому говорить об отборе 101 тысячи из 140 тысяч оснований нет. Число около 140 тысяч к этой части данных не относится.

101 093, 6 980 и 1 179: как эти числа связаны?

Резервный слайд 21

101 093 запроса входят в полную dev-часть. dev/small содержит 6 980 из них и исходные оценки релевантности для стандартного оценивания. Ручная подвыборка содержит 1 179 запросов из dev/small. Один запрос может иметь много кандидатов, поэтому в ручной части 33 667 пар. Размер корпуса другой: 8 841 823 фрагмента.

Мы учились и тестировались на dev MS MARCO?

Резервный слайд 23

Дообучение нашего судьи и его локальная проверка выполнялись на ручной подвыборке из dev/small. Мы отдельно разделили её на 825 обучающих, 177 валидационных и 177 тестовых запросов. Это внутренние части эксперимента, а не официальный закрытый test MS MARCO. Исходный MiniLM уже был предварительно обучен; проверка исключает пересечение запросов в нашем дообучении, но сама по себе не доказывает отсутствие пересечений с его предобучением.

Почему для ручной разметки выбраны именно 1 179 запросов?

Резервный слайд 21

Это объём подготовленной ручной подвыборки, на которой выполнен эксперимент. Её принадлежность dev/small проверена по идентификаторам. Случайный или репрезентативный отбор этих запросов в доступных материалах не подтверждён, поэтому заявлять его нельзя. Выводы ручного эксперимента относятся к этой подвыборке и её кандидатным пулам.

Что видел человек и что получает модель-судья?

Резервный слайд 26

Человек видел запрос, оцениваемый фрагмент и известный релевантный ответ. Подготовка ручных кандидатов также использовала сходство E5 с этим ответом. Судья получает только тексты запроса и кандидата. Он не получает известного ответа, позиций, баллов BM25, E5 или BGE и заранее рассчитанных эмбеддингов. Добавление эталонного ответа ко входу судьи предложено как следующий эксперимент.

Судья может быть слабее поисковых моделей. Зачем тогда он нужен?
Резервный слайд 23

Судья нужен как доступный способ получить много дополнительных оценок и исследовать зависимость метрик от охвата. Он не заменяет поисковые системы и не считается безошибочным эталоном. BM25, E5 и BGE по-прежнему находят и ранжируют кандидатов. На ручных данных их сравнение опирается на человеческие оценки. Масштабные выводы с MiniLM условны и требуют проверки более сильными судьями и независимой ручной разметкой.

Почему выбран MiniLM? Сравнивали ли другие cross-encoder?
Резервный слайд 26

Это компактная исходная модель cross-encoder/ms-marco-MiniLM-L6-v2, пригодная для оценки большого числа пар. В представленном эксперименте её дообучили на ручных оценках. Сравнения нескольких судей и модели со входом «запрос, эталонный ответ, кандидат» пока не выполнены. Результаты таких сравнений не заявляются.

Почему порог отрицательный и как его выбрали?
Резервный слайд 23

Используется ненормированный выходной балл модели. Его шкала допускает отрицательные числа и не совпадает со шкалой вероятностей от нуля до единицы. Порог −0,2187178284 выбрали на 177 валидационных запросах и затем не меняли ни для теста, ни для разных K. На слайдах значение округлено до −0,2187. Тестовая F1 при этом пороге равна 0,875.

Насколько часто судья ошибается?
Резервный слайд 23

На 5 002 тестовых парах получены 2 882 верных положительных и 1 300 верных отрицательных решения, 506 ложноположительных и 314 ложноотрицательных. Точность 0,851 означает, что около 85% положительных предсказаний совпали с целевыми ручными метками на этом тесте. Эти доли нельзя автоматически переносить на все более глубокие пулы.

Что такое K и чем оно отличается от L?
Резервный слайд 24

K определяет, сколько результатов от каждой системы попадает в пул разметки. L определяет, сколько результатов от каждой системы поступает на слияние RRF. В первом сравнении L равно K, поэтому меняются и пул, и итоговое ранжирование. В контрольном сравнении L всегда равно 200: выдача фиксирована, меняется только пул с оценками. Повторяющиеся кандидаты учитываются один раз.

У каждого из 101 093 запросов есть все три поисковых списка?
Резервный слайд 21

Для E5 и BGE сохранены выдачи для всех 101 093 запросов. У BM25 отсутствуют списки для трёх запросов, а некоторые списки короче заданной глубины. Пулы строятся из доступных результатов. Для отсутствующего документа вклад

соответствующего источника в RRF равен нулю. Число 101 093 описывает весь набор запросов, а не гарантию трёх полных списков у каждого.

RRF усредняет предсказания моделей или ответы судьи?

Резервный слайд 24

Нет. RRF суммирует величины, зависящие от места документа в списках BM25, E5 и BGE: 1/(60 + место). Веса источников одинаковы. Сырые поисковые баллы и оценки судьи в формулу не входят. Например, первое место у любого источника даёт вклад 1/61. Судья используется отдельно для оценки полученного списка.

Если NDCG выросла, значит поиск стал лучше?

Резервный слайд 22

В ручном сравнении поисковая выдача не менялась. Изменились метки, по которым мы её оцениваем: ранее неоценённые полезные ответы стали давать вклад в метрику. Поэтому выросла измеренная оценка качества, а не возможности самой поисковой модели. NDCG@10 учитывает релевантность в первой десятке с большим весом верхних позиций и нормирует её относительно идеальной выдачи.

Ручные запросы входят в масштабный эксперимент. Это утечка?

Резервный слайд 25

Полная dev-часть действительно включает ручные запросы, в том числе использованные для дообучения судьи. Поэтому все 101 093 запроса нельзя называть независимым тестом судьи. Мы отдельно исключили все 1 179 ручных запросов: осталось 99 914. Знаки различий RRF и E5 сохранились на проверенных глубинах. Это проверка устойчивости сравнения, а не замена независимой человеческой оценки глубоких пулов.

Значит, на каждый запрос есть 17 или 129 правильных ответов?

Резервный слайд 24

17,47 относится к среднему числу положительных человеческих оценок внутри ручных пулов. 128,6 относится к положительным предсказаниям одного судьи при K = 200 на полной dev-части. Пулы целенаправленно отобраны поисковыми методами. Ни одно число не оценивает полное количество релевантных ответов во всём корпусе.

Какие выводы можно переносить на другие данные?

Резервный слайд 25

Эксперимент показывает, что неполные оценки и выбранный пул могут существенно влиять на измеряемое качество. Конкретные численные эффекты получены на англоязычных пулах MS MARCO. Их перенос на другие языки, предметные области и поисковые сервисы нужно проверять отдельно.