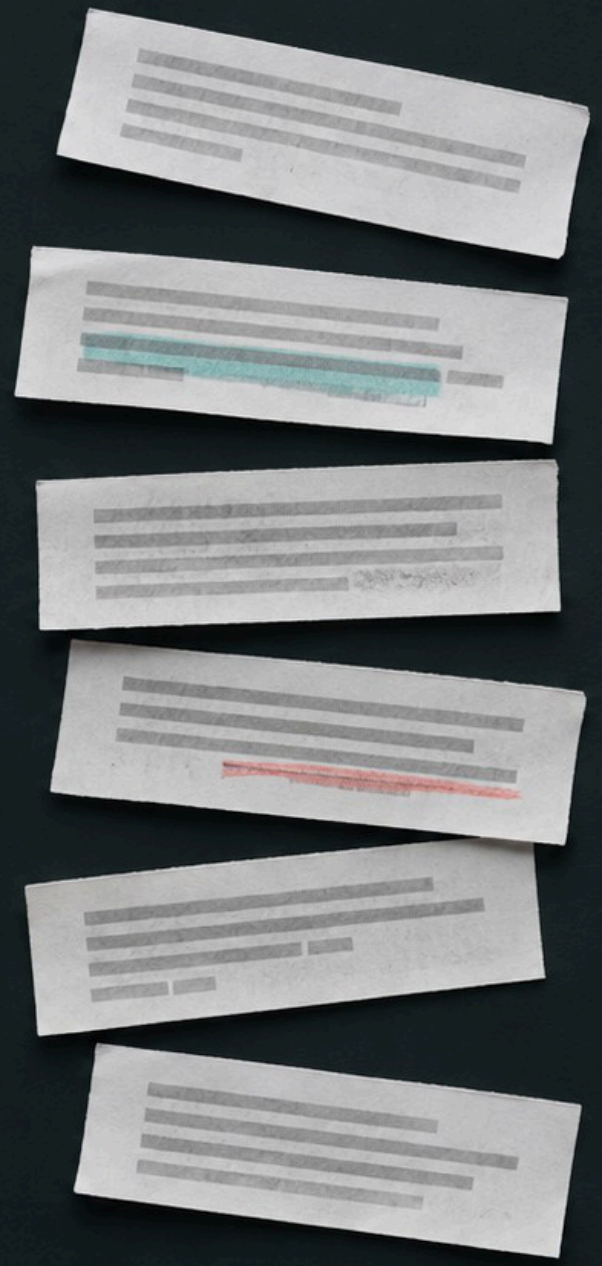
DAMDID 2026

Доразметка и контролируемые пулы кандидатов

Переоценка поисковых моделей на MS MARCO



Наборы данных для оценки поиска

Набор / бенчмарк	Источник и задача
Natural Questions	Запросы Google, ответы в Wikipedia
BEIR	Разные задачи и домены поиска
MS MARCO	**Запросы Bing, поиск по веб-фрагментам**

Почему MS MARCO

Открытые тексты и разреженные оценки релевантности

Источники: Bajaj и др., 2016/2018; Kwiatkowski и др., 2019; Thakur и др., 2021.

Близкие результаты ведущих систем

MS MARCO Passage Ranking, тест eval, исторический срез 30.11.2022

Система	MRR@10
AliceMind SLM + HLAR	0,450
Listwise + Fusion	0,440
CoT-MAE	0,438
Lichee + DeBERTa + reranking	0,436

0,014

размах значений

MRR@10: обратная позиция первого релевантного ответа в топ-10, в среднем.

Близкие метрики не доказывают равенство качества.

Microsoft, четыре ведущие именованные системы в режиме полного поиска.

Релевантный ответ без оценки

«Что вызывает повышение температуры кипения?»

Сокращённый пересказ фрагмента	Исходные оценки	Оценка человека
7112148 Добавление соли повышает температуру кипения.	Релевантен	Релевантен
7399382 Нелетучее растворённое вещество повышает температуру кипения.	Нет оценки	**Релевантен**
987600 Температура кипения ацетона.	Нет оценки	Нерелевантен

qrels: оценки релевантности. Нет оценки: нулевой вклад.
Русский пересказ исходных фрагментов. Метки относятся к оригиналам.

Данные и покрытие разметкой

Англоязычный MS MARCO

8,84 млн текстовых фрагментов

Оценки человека

1 179

запросов, 33 667 пар

Предсказания судьи

101 093

запроса, разная глубина пулов

Глубокая доразметка: оценивание многих кандидатов внутри заданного пула.

Разметка с известным релевантным ответом



Известный ответ используется при отборе кандидатов и ручной разметке.

Больше оценок в тех же пулах

Среднее число релевантных фрагментов на запрос

1,05

17,47

Исходные оценки

1 243 релевантные пары

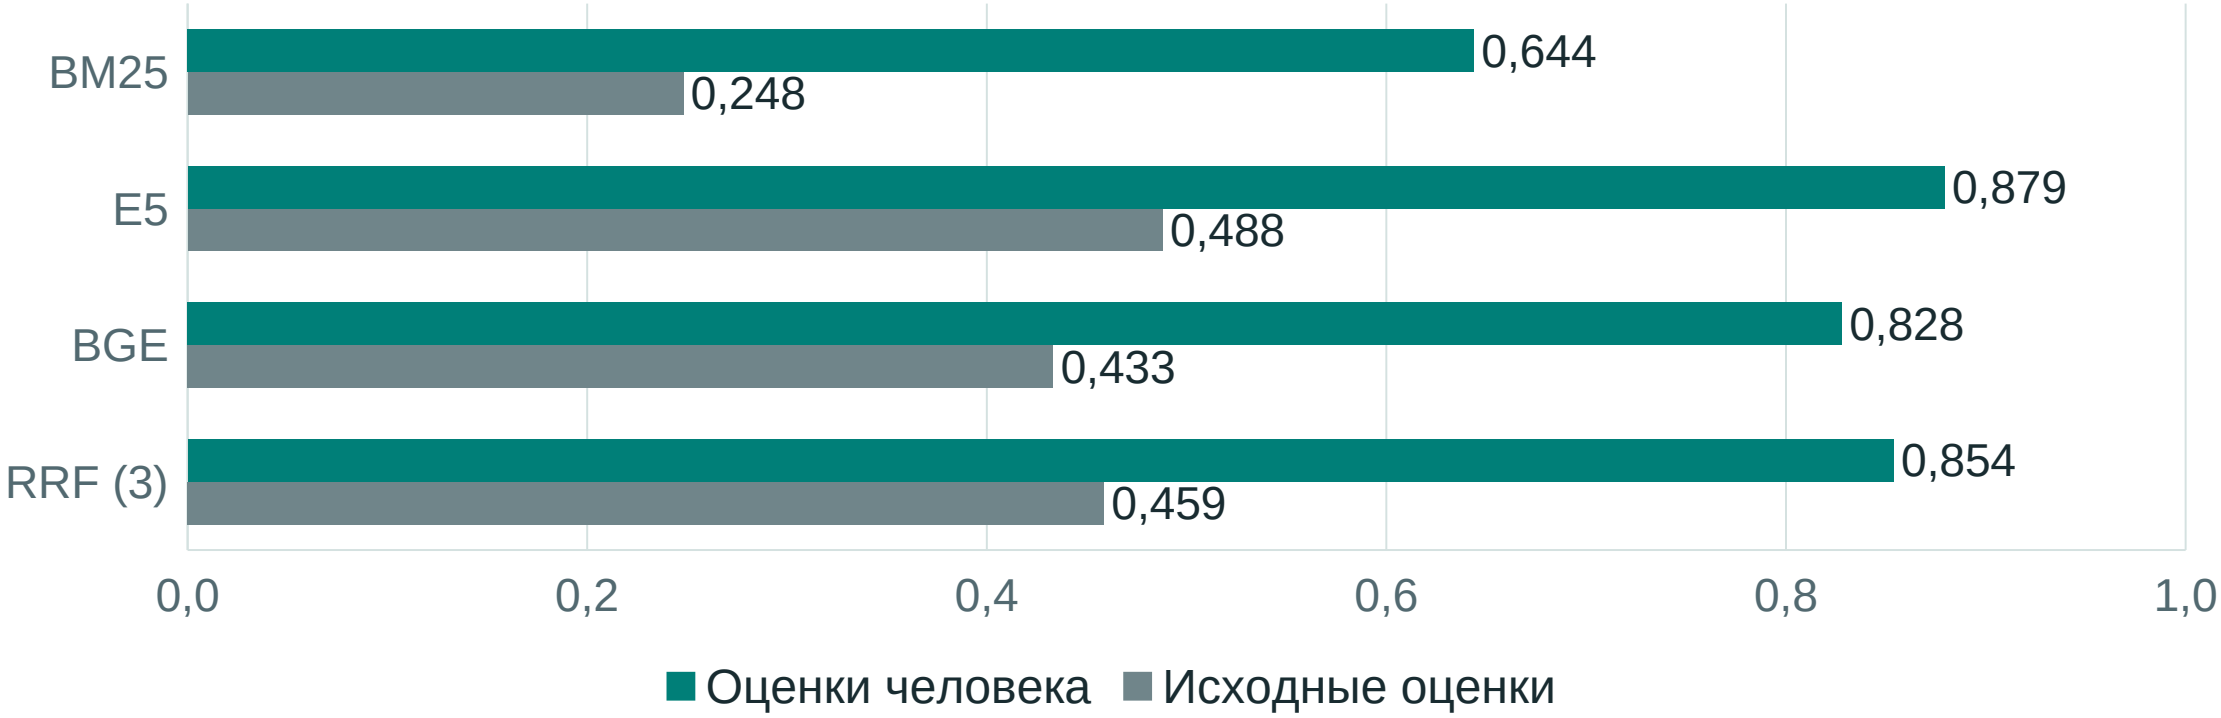
После доразметки

20 597 релевантных пар

1 179 запросов. Пулы кандидатов и порядок поисковой выдачи неизменны.

Доразметка меняет оценку NDCG@10

RRF: объединение выдач BM25, E5 и BGE по обратным рангам

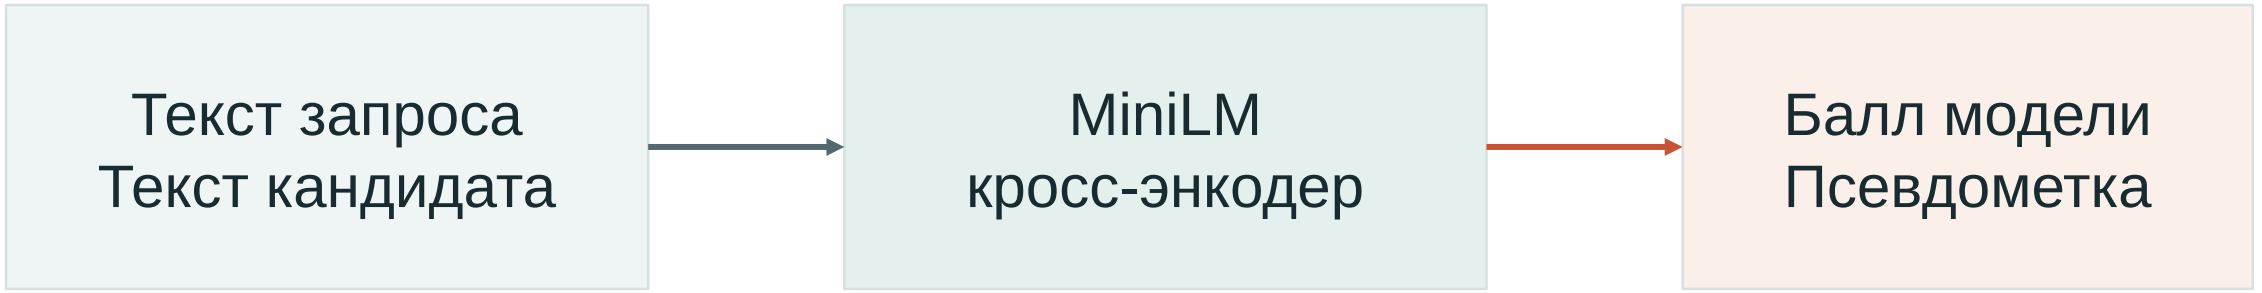


Изменение E5: +0,391 95%-ный ДИ [0,365; 0,417]

NDCG@10 внутри пулов. Общий идеальный знаменатель для запроса и набора меток.

Модель-судья для больших пулов

Ручные оценки обучают судью для автоматической разметки.



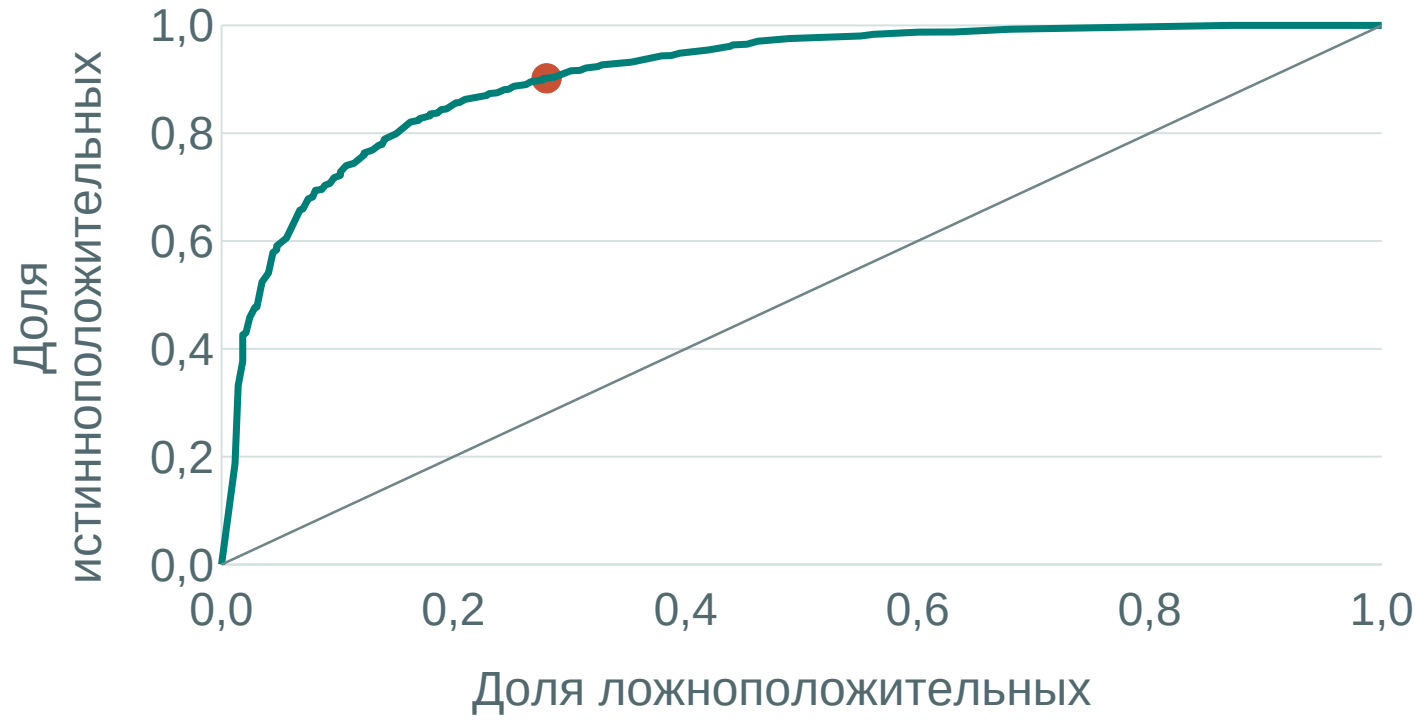
Совместно оценивает два текста

На входе нет эталонного ответа, рангов и баллов поисковых моделей.

Псевдометки остаются предсказаниями модели.

Согласие судьи с ручной разметкой

Тест: 177 отложенных запросов, 5 002 пары из ручных пулов



0,907

ROC-AUC

0,875

F1 при выбранном пороге

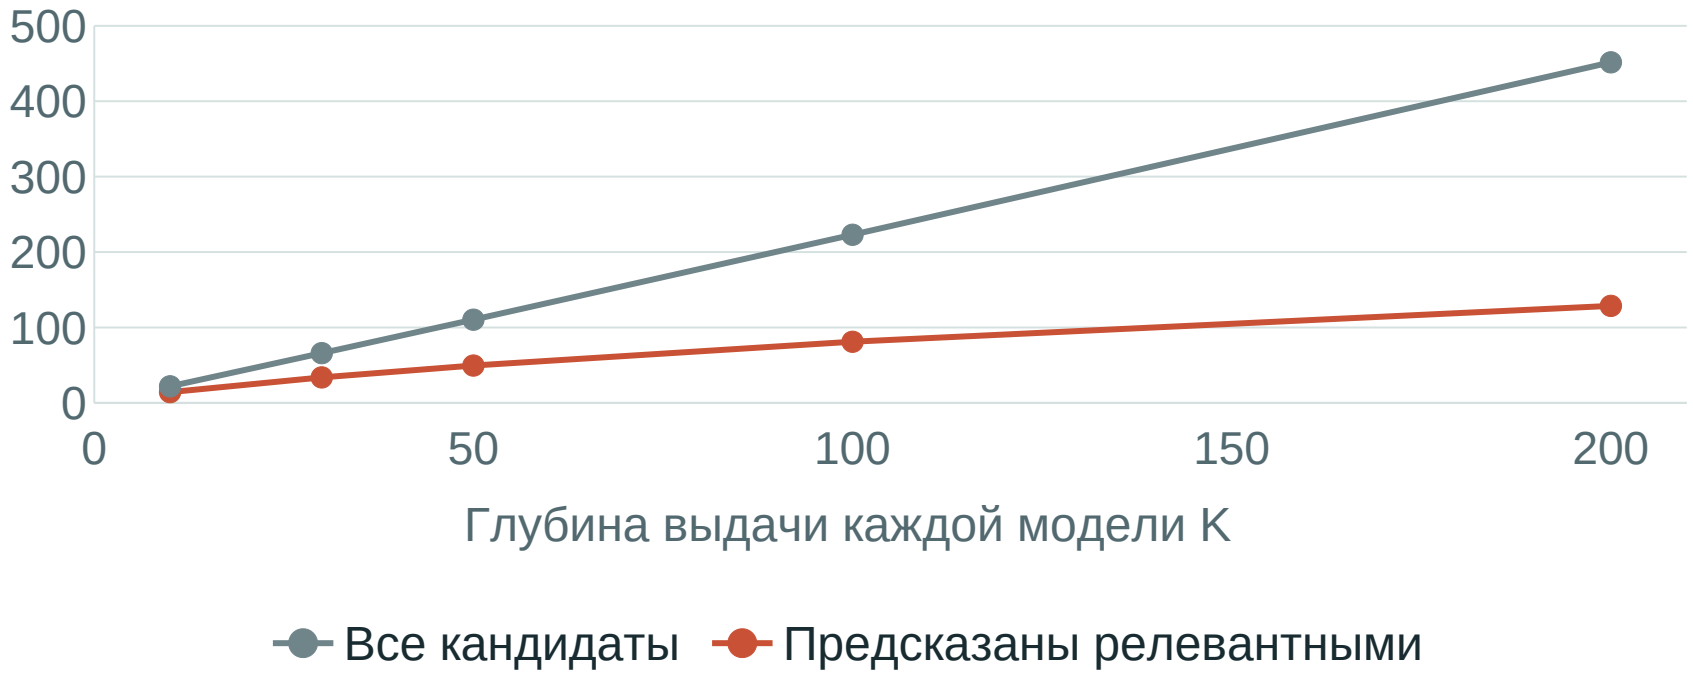
Точка: порог, выбранный на валидационных запросах

Для глубоких пулов нет независимой ручной проверки.

Размер пула и предсказанная релевантность

K: число результатов каждой модели для оценочного пула

Среднее число фрагментов на запрос



451,5

кандидата

128,6

по судье
при K = 200

101 093 запроса, включая пулы без положительных меток. Судья и порог неизменны.

Меняются пул и входные списки RRF

K: глубина пула L: глубина входных списков RRF

Обе глубины меняются одновременно: L = K



При K = 200 разность NDCG@10 составляет +0,0088

Один судья. 95%-ный парный ДИ [0,0082; 0,0095].
Бутстрэп по запросам не учитывает неопределённость судьи.

Покрытие разметкой меняет сравнение

K: глубина пула L: глубина входных списков RRF

Меняется только K. L = 200, обе выдачи зафиксированы.



14,4%

пар из топ-10 RRF вне оценочного пула при K = 10

145 643 пары «запрос–фрагмент»

K = 10: −0,0661

K = 30: +0,0080

RRF минус E5 по псевдометкам. Фрагменты без оценки дают нулевой вклад.

Устойчивость и ограничения

Сравнение после исключения части запросов

Оценивание	Запросов	Результат
Ручная разметка Исключены 23 запроса	1 156	Порядок систем сохранён
Псевдометки Без ручных запросов	99 914	Знаки разностей RRF–E5 сохранены

Ручные пулы: известный ответ, согласие экспертов не измерено.

Большие пулы: один судья, без независимой ручной проверки.

Перенос за пределы выбранных пулов английского MS MARCO не проверен.

Полнота разметки влияет на оценку поиска

Оценки человека

E5 NDCG@10: с 0,488 до 0,879

Та же выдача, более полная разметка

Фиксированные выдачи, один судья

Расширение пула может изменить порядок RRF и E5

Далее: более сильные судьи с эталонным ответом и без него.
Проверка по независимым человеческим оценкам.

Результаты для выбранных пулов английского MS MARCO.

NDCG@10 и эффект доразметки

NDCG@10 = DCG@10 / идеальный DCG@10

Система	После − до	95%-ный парный ДИ
BM25	+0,396	0,372 ... 0,419
E5	+0,391	0,365 ... 0,417
BGE	+0,395	0,369 ... 0,419
RRF (3)	+0,395	0,371 ... 0,419

5 000 парных бутстрэп-выборок по запросам. Для всех четырёх эффектов $p < 0,001$.

Проверка судьи и ошибки

Обучение	Валидация	Тест
825	**177**	**177**

Метка в тесте	Прогноз: нет	Прогноз: да
Отрицательная	1 300	506
Положительная	314	2 882

Точность 0,851 **Полнота 0,902** **F1 0,875**

5 002 пары: 6 неясных меток кодируются нулём, у 1 записи пустой текст.

Результаты при разной глубине пула

K	Кандидатов на запрос	Релевантных по судье на запрос	E5 NDCG@10	RRF L=K NDCG@10	RRF L=200 NDCG@10
10	21,9	14,2	0,871	0,852	0,805
30	65,8	33,7	0,851	0,862	0,859
50	110,4	49,4	0,847	0,856	0,856
100	222,9	81,0	0,844	0,851	0,853
200	451,5	128,6	0,842	0,850	0,850

Псевдометки одного судьи. В каждом среднем учтены все 101 093 запроса.

Чувствительность к исключению запросов

NDCG@10 по ручным оценкам

Система	Все 1 179 запросов	1 156 после исключения
BM25	0,644	0,644
E5	0,879	0,879
BGE	0,828	0,828
RRF (3)	0,854	0,855

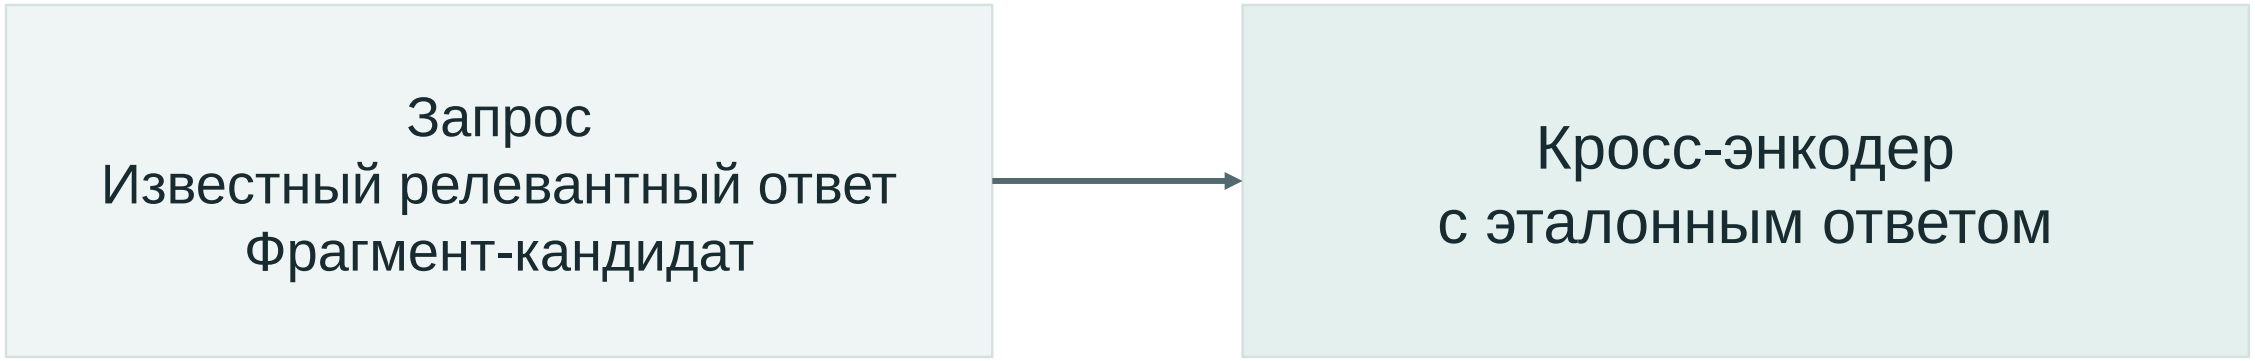
Большой набор без ручных запросов: N = 99 914

При K = 200: RRF − E5 = +0,00877

Проверки исключением не заменяют независимую ручную оценку.

Следующий шаг: судья с эталонным ответом

Предлагаемый вход



Сравнение более сильных судей по независимым человеческим оценкам

Запланированный эксперимент. Результаты для такого судьи пока не получены.