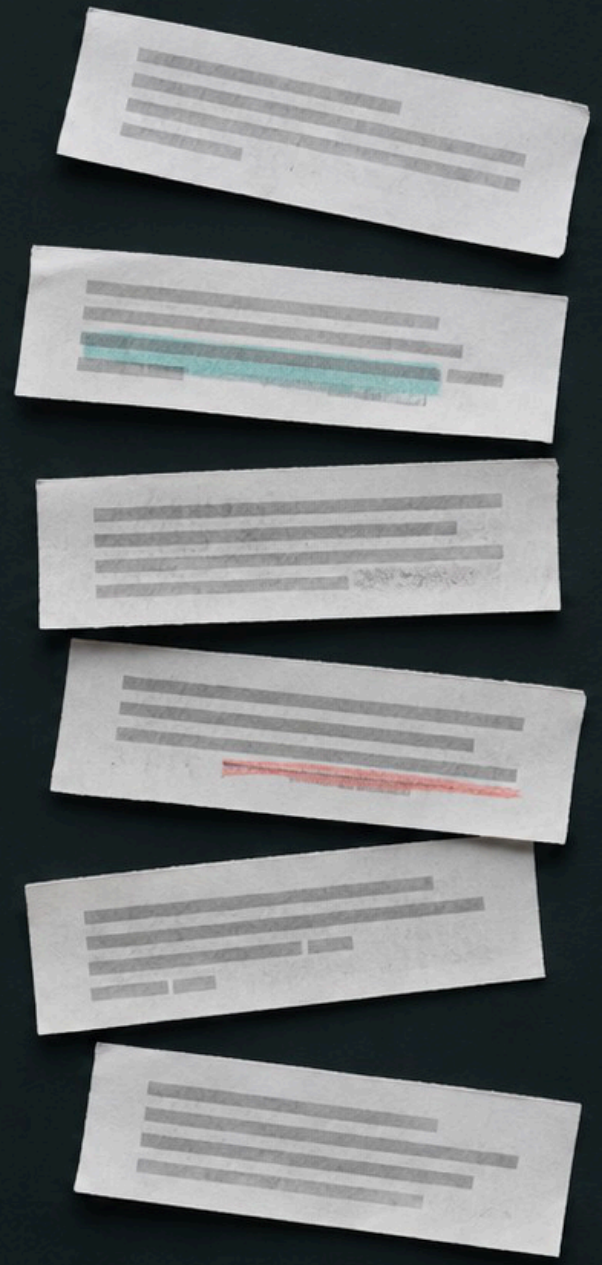
DAMDID 2026

Доразметка и контролируемые пулы кандидатов

Переоценка поисковых моделей на MS MARCO



Наборы данных для оценки поиска

Набор / бенчмарк	Источник и задача
Natural Questions	Запросы Google, ответы в Wikipedia
BEIR	Разные задачи и домены поиска
MS MARCO	**Запросы Bing, поиск по веб-фрагментам**

Почему MS MARCO

Открытые тексты и разреженные оценки релевантности

Источники: Bajaj и др., 2016/2018; Kwiatkowski и др., 2019; Thakur и др., 2021.

Близкие результаты ведущих систем

MS MARCO Passage Ranking, полный поиск, тестовый набор eval

Система	MRR@10
AliceMind SLM + HLAR	0,450
Listwise + Fusion	0,440
CoT-MAE	0,438
Lichee + DeBERTa + reranking	0,436

0,014

размах значений

MRR@10: обратная позиция первого релевантного ответа в топ-10, в среднем.

Близкие метрики не доказывают равенство качества.

Microsoft, четыре ведущие именованные системы. Срез на 30.11.2022.

Релевантный ответ без оценки

«Что вызывает повышение температуры кипения?»

Фрагмент в сокращении	Исходные оценки	Оценка человека
7112148 Добавление соли повышает температуру кипения.	Релевантен	Релевантен
7399382 Нелетучее растворённое вещество повышает температуру кипения.	Нет оценки	**Релевантен**
987600 Температура кипения ацетона.	Нет оценки	Нерелевантен

qrels: оценки релевантности. Нет оценки: нулевой вклад. Тексты переведены и сокращены.

Данные и покрытие разметкой

Англоязычный MS MARCO

8,84 млн текстовых фрагментов

Оценки человека

1 179

запросов, 33 667 пар

Предсказания судьи

101 093

запроса, разная глубина пулов

Глубокая доразметка: оценивание многих кандидатов внутри заданного пула.

Разметка с известным релевантным ответом



Известный ответ используется при отборе кандидатов и ручной разметке.

Больше оценок в тех же пулах

Среднее число релевантных фрагментов на запрос

1,05

17,47

Исходные оценки

1 243 релевантные пары

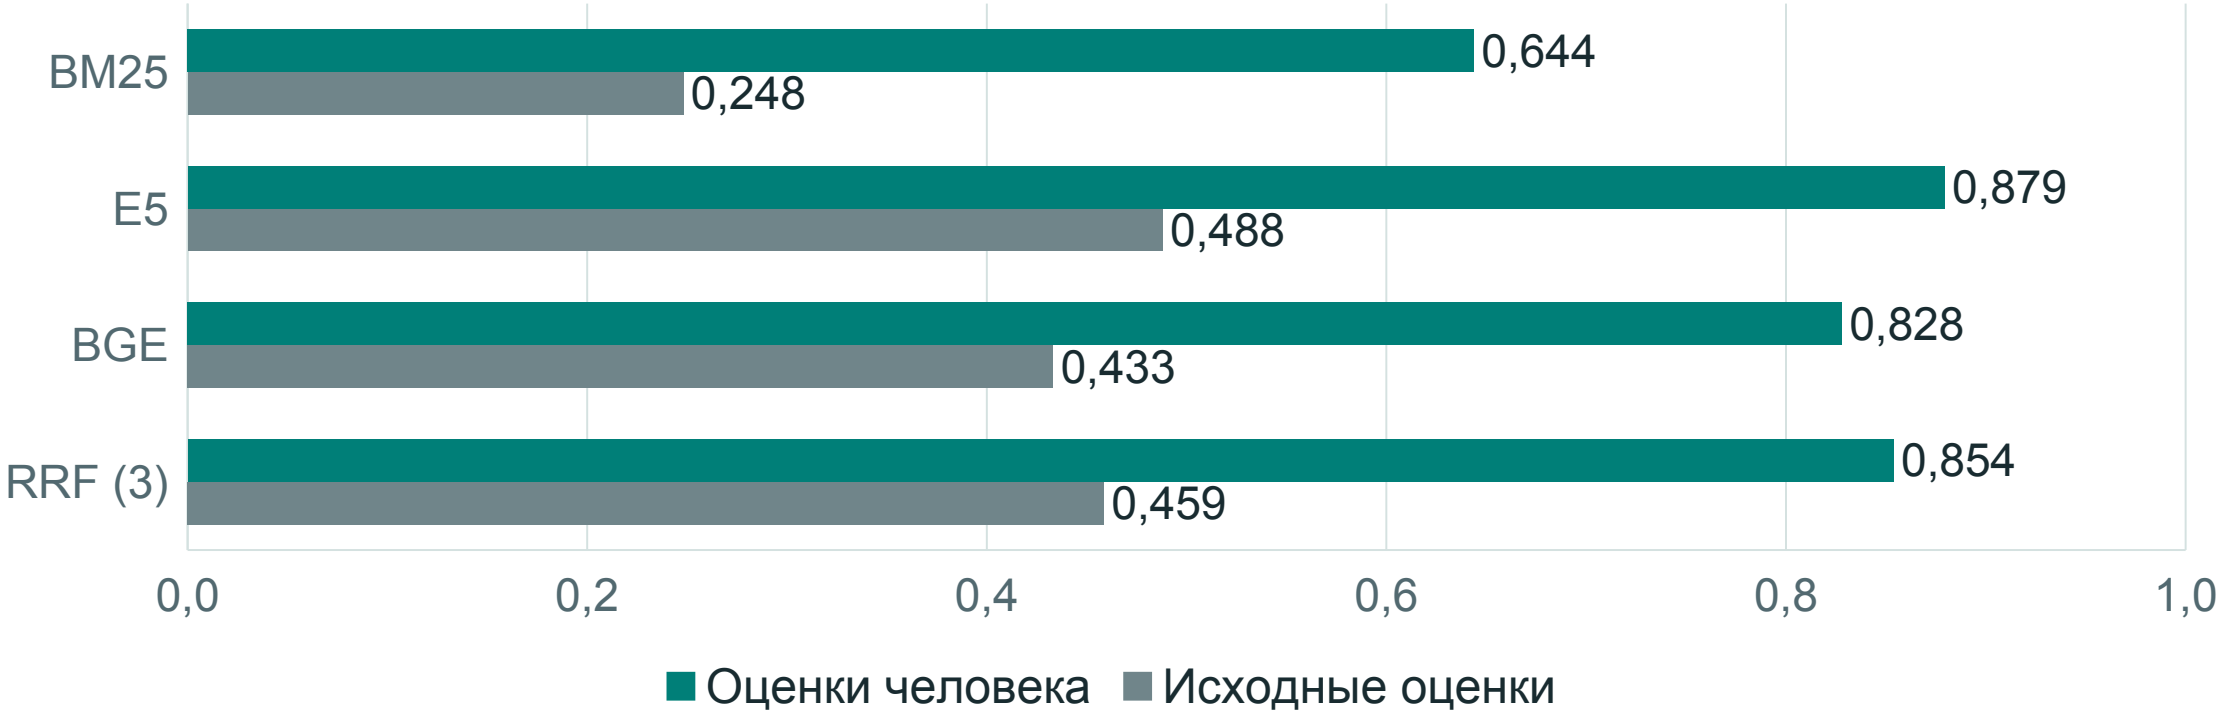
После доразметки

20 597 релевантных пар

1 179 запросов. Пулы кандидатов и порядок поисковой выдачи неизменны.

Доразметка меняет оценку NDCG@10

RRF: объединение выдач BM25, E5 и BGE по обратным рангам

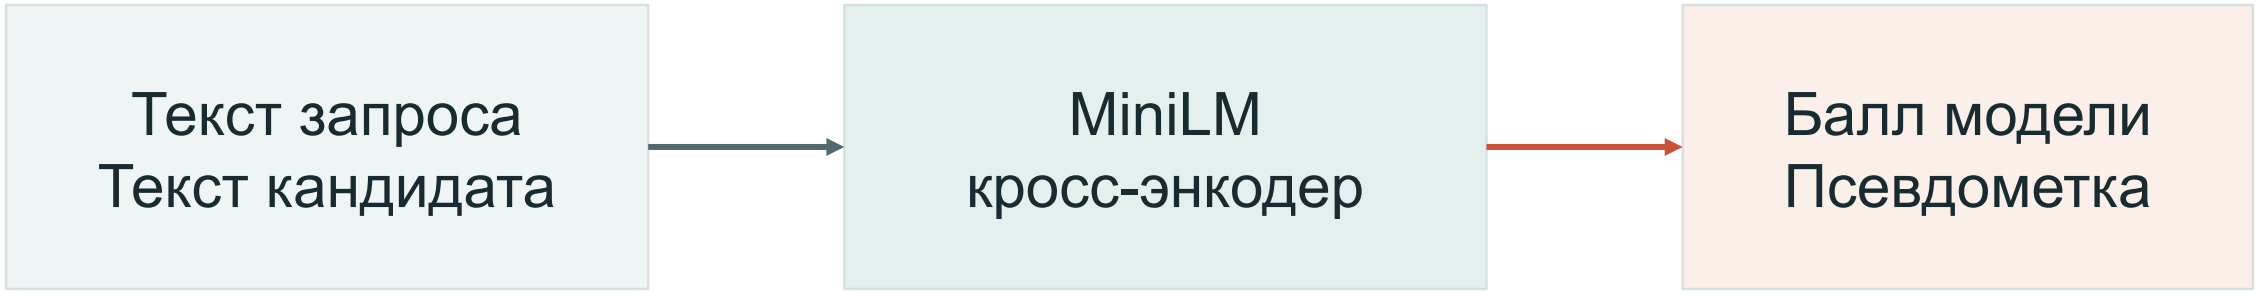


Изменение E5: +0,391 95%-ный ДИ [0,365; 0,417]

NDCG@10 внутри пулов. Общий идеальный знаменатель для запроса и набора меток.

Модель-судья для больших пулов

Ручные оценки обучают судью для автоматической разметки.



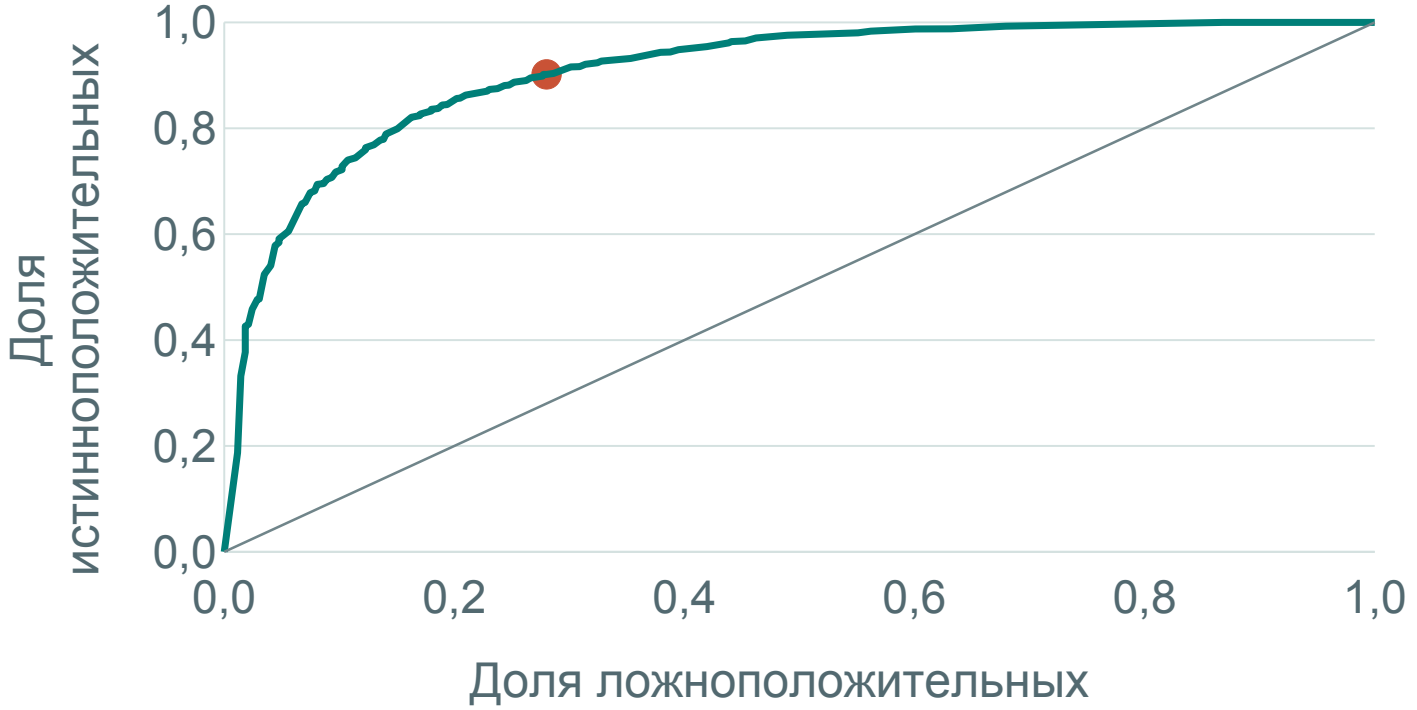
Совместно оценивает два текста

На входе нет эталонного ответа, рангов и баллов поисковых моделей.

Псевдометки остаются предсказаниями модели.

Согласие судьи с ручной разметкой

Тест: 177 отложенных запросов, 5 002 пары из ручных пулов



0,907

ROC-AUC

0,875

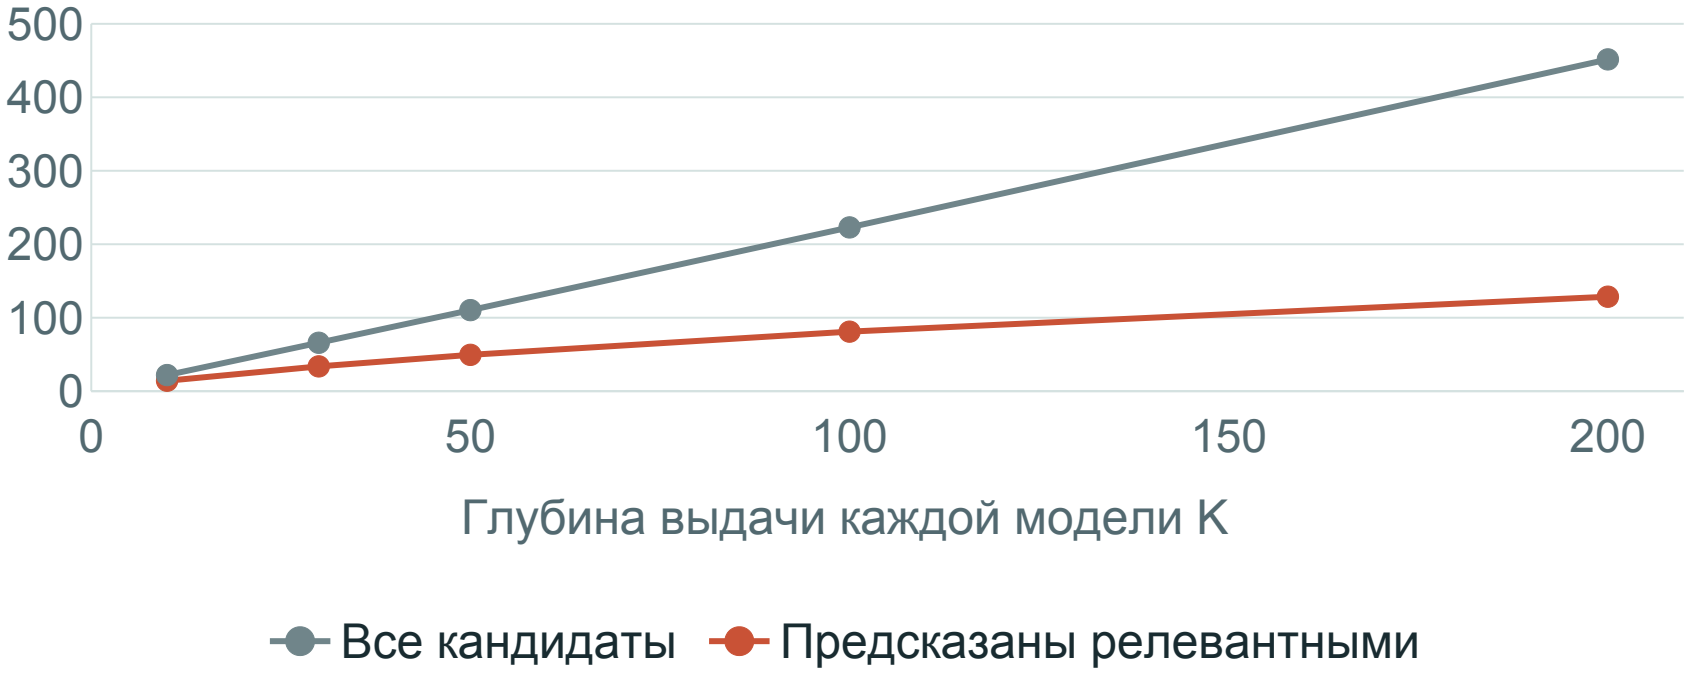
F1 при выбранном пороге

Точка: порог, выбранный на валидационных запросах

Для глубоких пулов нет независимой ручной проверки.

Размер пула и предсказанная релевантность

K: число результатов каждой модели для оценочного пула



451,5

кандидата

128,6

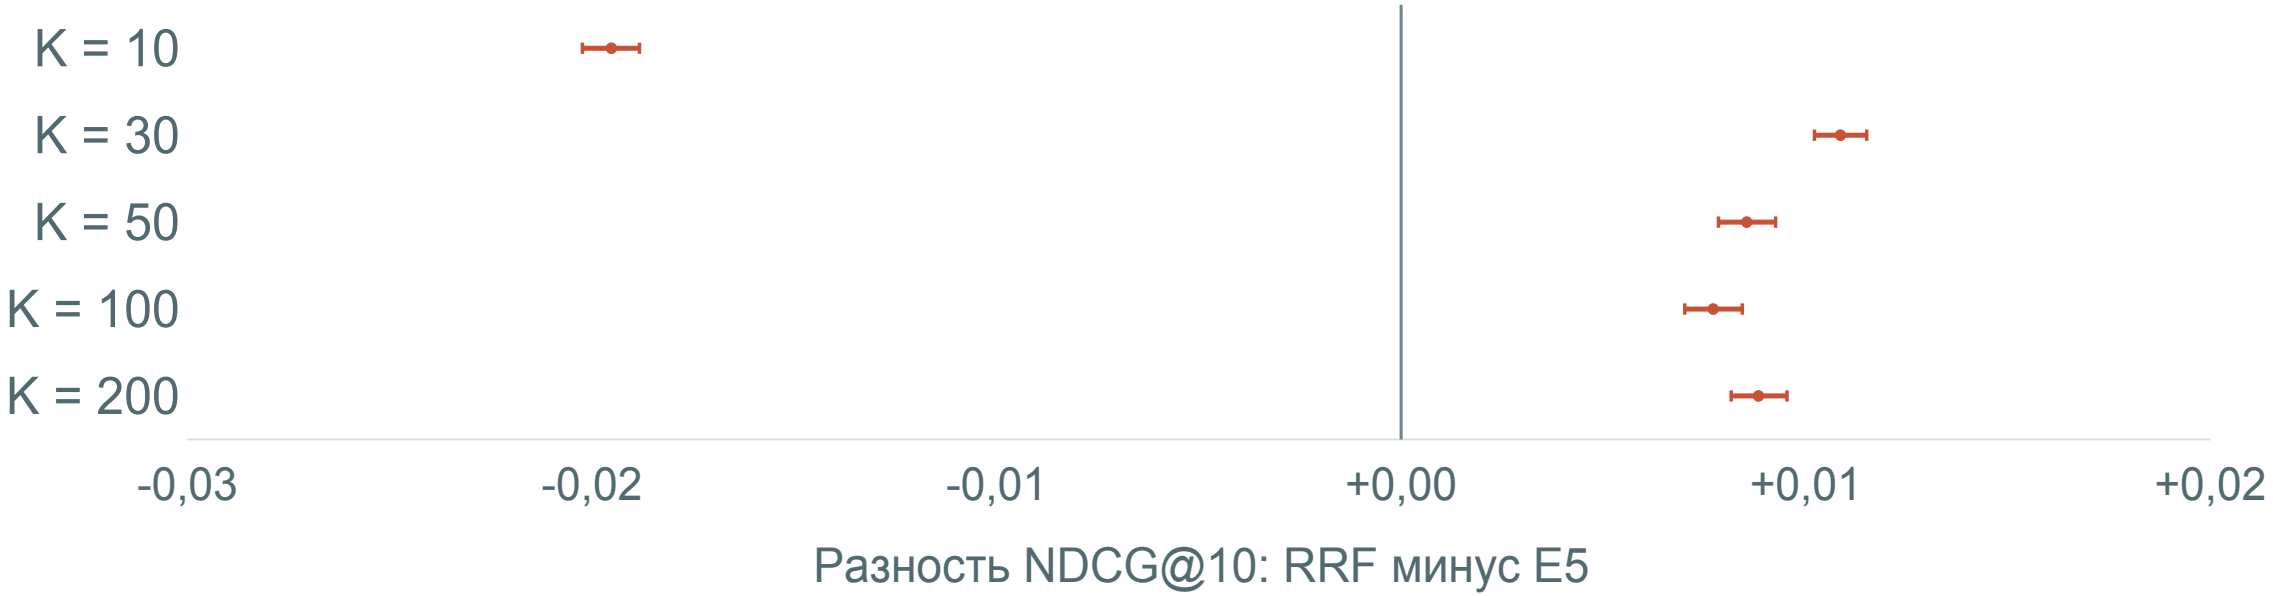
релевантных по судье при K = 200

101 093 запроса, включая пулы без положительных меток. Судья и порог неизменны.

Меняются пул и входные списки RRF

K: глубина пула L: глубина входных списков RRF

Обе глубины меняются одновременно: L = K



При K = 200 разность NDCG@10 составляет +0,0088

Один судья. 95%-ный парный ДИ [0,0082; 0,0095].
Бутстрэп по запросам не учитывает неопределённость судьи.

Покрытие разметкой меняет сравнение

K: глубина пула L: глубина входных списков RRF

Меняется только K. L = 200, обе выдачи зафиксированы.



14,4%

пар из топ-10 RRF вне оценочного пула при K = 10

145 643 пары «запрос–фрагмент»

K = 10: −0,0661

K = 30: +0,0080

RRF минус E5 по псевдометкам. Фрагменты без оценки дают нулевой вклад.

Устойчивость и ограничения

Сравнение после исключения части запросов

Оценивание	Запросов	Результат
Ручная разметка Исключены 23 запроса	1 156	Порядок систем сохранён
Псевдометки Без ручных запросов	99 914	Знаки разностей RRF–E5 сохранены

Ручные пулы: известный ответ, согласие экспертов не измерено.

Большие пулы: один судья, без независимой ручной проверки.

Перенос за пределы выбранных пулов английского MS MARCO не проверен.

Полнота разметки влияет на оценку поиска

Оценки человека

E5 NDCG@10: с 0,488 до 0,879

Та же выдача, более полная разметка

Фиксированные выдачи, один судья

Расширение пула может изменить порядок RRF и E5

Далее: более сильные судьи с эталонным ответом и без него.
Проверка по независимым человеческим оценкам.

Результаты для выбранных пулов английского MS MARCO.

NDCG@10 и эффект доразметки

NDCG@10 = DCG@10 / идеальный DCG@10

Система	После − до	95%-ный парный ДИ
BM25	+0,396	0,372 ... 0,419
E5	+0,391	0,365 ... 0,417
BGE	+0,395	0,369 ... 0,419
RRF (3)	+0,395	0,371 ... 0,419

5 000 парных бутстрэп-выборок по запросам. Для всех четырёх эффектов $p < 0,001$.

Проверка судьи и ошибки

Обучение	Валидация	Тест
825	**177**	**177**

Метка в тесте	Прогноз: нет	Прогноз: да
Отрицательная	1 300	506
Положительная	314	2 882

Точность 0,851 **Полнота 0,902** **F1 0,875**

5 002 пары: 6 неясных меток кодируются нулём, у 1 записи пустой текст.

Результаты при разной глубине пула

K	Кандидатов на запрос	Релевантных по судье на запрос	E5 NDCG@10	RRF L=K NDCG@10	RRF L=200 NDCG@10
10	21,9	14,2	0,871	0,852	0,805
30	65,8	33,7	0,851	0,862	0,859
50	110,4	49,4	0,847	0,856	0,856
100	222,9	81,0	0,844	0,851	0,853
200	451,5	128,6	0,842	0,850	0,850

Псевдометки одного судьи. В каждом среднем учтены все 101 093 запроса.

Чувствительность к исключению запросов

NDCG@10 по ручным оценкам

Система	Все 1 179 запросов	1 156 после исключения
BM25	0,644	0,644
E5	0,879	0,879
BGE	0,828	0,828
RRF (3)	0,854	0,855

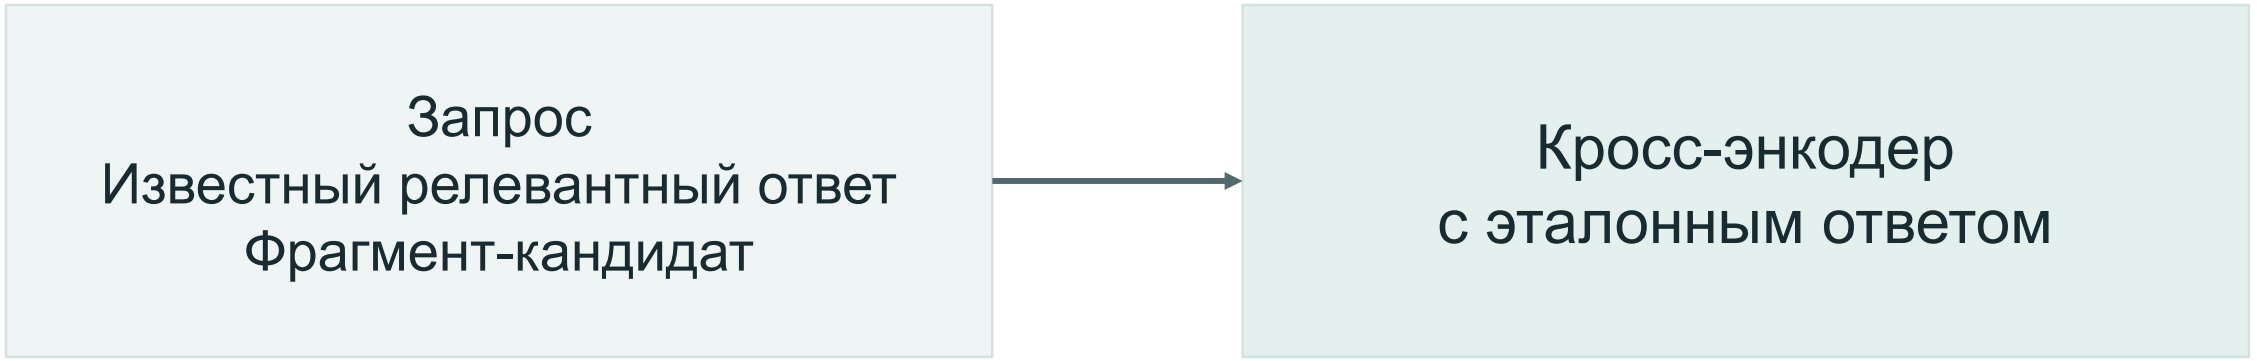
Большой набор без ручных запросов: N = 99 914

При K = 200: RRF − E5 = +0,00877

Проверки исключением не заменяют независимую ручную оценку.

Следующий шаг: судья с эталонным ответом

Предлагаемый вход



Сравнение более сильных судей по независимым человеческим оценкам

Запланированный эксперимент. Результаты для такого судьи пока не получены.