Текст выступления DAMDID 2026

Доразметка и контролируемые пулы кандидатов для переоценки поисковых моделей на MS MARCO

Русскоязычный доклад по слайдам 1–15. Слайды 16–20 оставлены для вопросов. Расчётный хронометраж: 15:10 при темпе около 120 слов в минуту с короткими переходами. Точное время проверьте на репетиции. Заголовки и отметки времени не нужно зачитывать.

Слайд 1 Введение

0:00–0:35

углублённой доразметке MS MARCO и оценке поиска на контролируемых пулах

Главный вопрос работы: насколько оценка поисковой системы зависит от того, какие фрагменты текста получили оценку релевантности? Чтобы разобраться в этом, сначала поясню, почему для исследования мы выбрали именно MS MARCO.

Слайд 2 Почему мы выбрали MS MARCO

0:35–1:25

Для оценки поиска существуют разные наборы данных. В Natural Questions используются реальные запросы Google и ответы в статьях Википедии. BEIR объединяет разные задачи и предметные области, чтобы проверять переносимость поисковых методов.

Мы выбрали MS MARCO. Он основан на реальных запросах Bing и содержит открытые тексты веб-фрагментов. Для нашей задачи особенно важна разреженность оценок релевантности: исходная разметка может не охватывать все подходящие ответы. Это позволяет исследовать, как дополнительная разметка меняет оценку поиска. При этом MS MARCO не представляет все поисковые сценарии, поэтому перенос наших выводов на другие коллекции требует отдельной проверки.

Слайд 3 Близкие метрики ведущих систем

1:25–2:30

Посмотрим на внешний ориентир: исторический срез официальной таблицы MS MARCO на ноябрь 2022 года. Здесь четыре ведущие системы с опубликованными названиями, все в одной постановке полного поиска и на одном закрытом тестовом наборе. Их MRR на первых десяти позициях лежит в диапазоне от 0,436 до 0,450. Эта метрика усредняет обратную позицию первого найденного релевантного ответа в первой десятке.

Размах опубликованных оценок составляет 0,014. Значения близки, но это ещё не доказывает ни равенство систем, ни неполноту разметки. Мы задаём отдельный вопрос: насколько сравнение зависит от того, какие ответы вообще оценены?

Следующий пример показывает проблему, которую мы исследуем. А в собственных экспериментах далее используем другую метрику, NDCG, рассчитанную внутри размеченных пулов. Напрямую сравнивать её с этой таблицей нельзя.

Слайд 4 Релевантный фрагмент без оценки

2:30–3:25

В этом примере запрос звучит так: что вызывает повышение температуры кипения? Первый фрагмент говорит о добавлении соли и отмечен как релевантный в исходной разметке. Второй объясняет роль нелетучего растворённого вещества. Человек тоже считает его релевантным, однако в исходной разметке оценки для него нет. Третий фрагмент сообщает температуру кипения ацетона, но не отвечает на вопрос о причине её повышения.

Оценки релевантности обычно называют qrels, от английского query relevance judgments. Это оценки того, насколько текст соответствует запросу. В нашем расчёте метрики неразмеченный фрагмент даёт нулевой вклад. Получается, система может найти полезный ответ, но не получить за него баллов. Отсутствие оценки не означает нерелевантность. Именно эту проблему мы исследуем.

Слайд 5 Данные и охват разметки

3:25–4:20

Мы используем англоязычную коллекцию фрагментов MS MARCO: в ней около 8,84 миллиона текстов. Исследование состоит из двух частей. Ручная часть охватывает 1179 запросов и 33 667 пар из запроса и фрагмента. В масштабной части модель-судья оценивает кандидатов для чуть более 101 тысячи запросов; глубина пула при этом меняется.

Эти части дают разные основания для выводов. В первой мы опираемся на оценки людей, во второй используем предсказания модели. Под углублённой доразметкой здесь понимается оценка множества кандидатов внутри заданного пула. Слово «углублённая» относится к охвату разметки, а не к глубине нейросети. Мы не утверждаем, что полностью разметили весь корпус.

Слайд 6 Подготовка пулов для ручной разметки

4:20–5:25

Для подготовки ручной выборки мы применили пулинг: объединили списки кандидатов и удалили дубликаты. BM25 ищет по лексическим совпадениям. E5 и BGE используют плотные векторные представления: запрос и фрагмент кодируются отдельно. Каждый сохранённый список, полученный поиском по запросу, добавляет в пул десять результатов.

Пул расширяют дополнительные способы отбора, в том числе поиск похожих фрагментов по E5 относительно заранее известного релевантного ответа. Разметчик также видит запрос, проверяемый фрагмент и этот ответ. Это разметка с опорой на эталон: она использует сведения, которых нет у обычной поисковой системы, получающей только запрос.

В среднем в пуле около 28,6 кандидата на запрос. Они отобраны целенаправленно и не являются случайной выборкой из корпуса. Это важно помнить, когда мы говорим о большом числе найденных релевантных фрагментов.

Слайд 7 Больше оценок в тех же пулах

5:25–6:20

В этих же пулах исходные qrels содержат 1243 пары с положительной оценкой. После расширенной ручной разметки таких пар становится 20 597. Среднее число фрагментов, признанных релевантными одному запросу, увеличивается с 1,05 до 17,47.

Это не значит, что исходные положительные оценки ошибочны. Просто многие другие подходящие ответы оставались без оценки. Вместе с тем наблюдаемый рост относится именно к отобранным пулам. По нему нельзя судить о количестве всех релевантных фрагментов в коллекции.

Теперь сравним оценки поисковых систем по двум вариантам разметки. Запросы, пулы кандидатов и порядок результатов поиска остаются прежними. Меняется только разметка релевантности. Так мы можем увидеть её влияние на измеряемое качество при неизменной выдаче.

Слайд 8 Оценки качества после доразметки

6:20–7:40

Качество ранжирования мы измеряем с помощью NDCG на первых десяти позициях. Метрика даёт больший вес релевантным фрагментам ближе к началу выдачи и нормирует результат относительно идеального порядка. Для одного запроса и одного набора меток знаменатель, соответствующий идеальной выдаче, одинаков у всех систем.

В сравнение включён и RRF, метод слияния по обратным рангам. Он объединяет списки BM25, E5 и BGE, используя позиции результатов, а не исходные численные оценки этих моделей.

Серые столбцы соответствуют исходным qrels, а зелёные показывают результаты по ручной разметке. Среднее качество растёт у всех четырёх систем. У E5 значение NDCG увеличивается с 0,488 до 0,879. Средний прирост в парном сравнении составляет около 0,391; доверительный интервал показан под графиком.

Здесь изменилась оценка качества благодаря более полной разметке. Сами поисковые системы мы не улучшали и не переобучали. Их порядок остаётся прежним: E5, RRF, BGE и BM25. Это результаты внутри размеченных пулов, а не показатели поиска по всему корпусу для общей таблицы лидеров.

Слайд 9 Зачем нужна модель-судья

7:40–8:40

Ручная разметка позволяет непосредственно изучить этот эффект, но оценивать таким способом гораздо более крупные пулы дорого. Поэтому мы дообучаем компактный кросс-энкодер MiniLM на человеческих оценках и используем его как модель-судью для получения псевдометок релевантности.

Кросс-энкодер обрабатывает запрос и проверяемый фрагмент совместно. Этим он отличается от E5 и BGE, которые строят отдельные представления запроса и

текста. На вход нашей модели-судьи поступают только эти два текста. Ни известного релевантного ответа, ни позиций в выдаче, ни оценок других моделей она не получает.

Порог принятия решения выбирается на валидационных запросах. Затем модель-судья позволяет исследовать охват разметки в большем масштабе. Но её метки остаются предсказаниями, а не человеческими оценками, поэтому согласие модели с ручной разметкой мы проверяем отдельно.

Слайд 10 Согласие на отложенных запросах

8:40–9:45

Ручные данные разделены на обучающую, валидационную и тестовую части по запросам. В тестовую часть входят 177 отложенных запросов и 5002 пары. Таким образом, качество проверяется на запросах, не использованных при обучении и выборе порога.

ROC-кривая показывает соотношение долей верно найденных положительных примеров и ложных срабатываний при изменении порога. Площадь под кривой равна 0,907. При пороге, выбранном на валидации, F1 составляет 0,875, точность около 0,851, а полнота около 0,902. Эти показатели описывают согласие с целевыми метками, полученными из человеческих оценок в ручных пулах.

Однако это не независимая проверка более глубоких пулов следующего эксперимента. Там могут встретиться другие кандидаты и другие ошибки. Поэтому результаты ручной разметки мы отделяем от масштабного эксперимента, который следует понимать как оценивание с помощью одной конкретной модели-судьи.

Слайд 11 Увеличение глубины пула

9:45–10:45

В масштабном эксперименте мы объединяем первые K результатов каждой системы: BM25, E5 и BGE. K обозначает число результатов от одного поискового метода, а не количество уникальных фрагментов после удаления дубликатов. Модель-судья и порог её решения остаются неизменными.

При увеличении K с десяти до двухсот средний размер пула растёт примерно с 22 до 452 кандидатов. Число фрагментов, которые модель считает релевантными, в среднем увеличивается примерно с 14 до 129. Эти средние рассчитаны по всем запросам, включая запросы без единого положительного предсказания.

Рост зависит от того, какой пул мы выбрали для оценки. Эти числа нельзя трактовать как количество всех подходящих ответов в корпусе. Далее посмотрим, как изменение охвата разметки влияет на сравнение поисковых систем.

Слайд 12 Изменение пула и глубины слияния

10:45–11:50

Здесь мы сравниваем RRF с E5 и различаем две глубины. K задаёт число результатов от каждой системы в пуле для разметки. L задаёт число результатов, поступающих на слияние рангов. В этой конфигурации обе величины растут вместе: L равно K.

По горизонтальной оси отложена разность NDCG: RRF минус E5. Значения слева от нуля означают преимущество E5, справа от нуля преимущество RRF. При K, равном десяти, RRF уступает. На четырёх больших глубинах разность небольшая, но положительная. При глубине двести она составляет около 0,0088.

Интервалы получены парным бутстрэпом по запросам. Они рассчитаны для фиксированной модели-судьи и не учитывают неопределённость её обучения и ошибки разметки. Кроме того, здесь одновременно меняются и охват, и входные

списки для слияния. Чтобы яснее выделить влияние охвата, дальше зафиксируем ранжирование.

Слайд 13 Охват меняется, выдача остаётся прежней

11:50–13:05

Теперь RRF всегда использует первые двести результатов каждого источника. Глубина L фиксирована, а первые десять результатов RRF и E5 не меняются. Варьируется только K, то есть глубина пула, для которого получаем оценки релевантности.

Даже при такой неизменной выдаче преимущество переходит от одной системы к другой. Разность RRF минус E5 составляет примерно минус 0,066 при K, равном десяти, и плюс 0,008 при K, равном тридцати.

Подпись справа помогает понять роль охвата. На минимальной глубине 14,4 процента пар из первых десяти результатов RRF оказываются за пределами размеченного пула. В метрике они получают нулевой вклад, поскольку не оценены. Это вовсе не означает, что все эти фрагменты релевантны.

Более широкий пул даёт оценки для большего числа найденных фрагментов и может изменить знаменатель, соответствующий идеальному ранжированию. Основной результат: измеряемый порядок систем способен измениться без изменения их выдачи. При этом вывод по-прежнему зависит от псевдометок одной модели-судьи.

Слайд 14 Устойчивость результатов и ограничения

13:05–14:10

Мы проверили чувствительность результатов к двум исключениям. В ручном эксперименте удалили 23 запроса, для которых оставались неясности с категориями меток или встречались пустые тексты. Порядок систем не изменился. В масштабном эксперименте после исключения всех запросов с ручной разметкой остаётся 99 914 запросов. Знаки различий между RRF и E5 сохраняются на всех проверенных глубинах.

Эти проверки касаются конкретных проблем данных и пересечения двух наборов запросов, но не устраняют все возможные смещения. Ручные пулы используют информацию об эталонном ответе; согласие между разметчиками не измерялось. Масштабный эксперимент опирается на одну компактную модель-судью, а более глубокие пулы не проходили независимую ручную проверку.

Поэтому наши выводы относятся к выбранным англоязычным пулам MS MARCO. Переносимость результатов на другие языки, предметные области и поисковые сервисы ещё предстоит проверить.

Слайд 15 Выводы и дальнейшая работа

14:10–15:10

Подведу итог. Более полная ручная разметка существенно меняет оценку уже полученных результатов поиска. В наших ручных пулах NDCG системы E5 увеличивается с 0,488 до 0,879 при совершенно неизменном ранжировании.

Масштабный эксперимент показывает, что охват разметки способен даже поменять местами RRF и E5 в сравнении качества при фиксированной выдаче обеих систем. Этот результат получен с одной моделью-судьёй и зависит от её оценок.

Поэтому вместе с метрикой качества поиска нужно указывать пул разметки, источник меток и настройки слияния. На следующем этапе мы сравним более сильные модели-судьи с доступом к известному релевантному фрагменту и без него, используя независимые человеческие оценки для проверки. Этот эксперимент запланирован, но пока не выполнен.

Спасибо за внимание! Буду рад вашим вопросам.